

## فصل ششم: یادگیری بیزی

استدلال بیز روشی احتمالی برای استنتاج ارائه می‌کند. این روش بر اساس این فرض است که کمیت‌های مورد نظر از توزیع‌های احتمال پیروی می‌کنند و تصمیم‌گیری بهینه را می‌توان با استدلال بر این توزیع‌های احتمال و داده‌های مشاهده شده انجام داد. اهمیت این روش در یادگیری ماشین این است که روشی کمی برای ارزیابی مدارک فرضیه‌ها ارائه می‌کند. استدلال بیزی اساس الگوریتم‌های یادگیری‌ای که با استفاده از احتمالات کار می‌کنند است. همچنین استدلال بیز چارچوبی<sup>۱</sup> برای بررسی عملیات دیگر الگوریتم‌هایی که از احتمالات استفاده نمی‌کنند ایجاد می‌کند.

### ۶.۱ معرفی

متد‌های یادگیری بیزی به دو دلیل به مطالعه‌ی ما در مورد یادگیری ماشین مربوط می‌شود. اول اینکه الگوریتم‌های یادگیری بیزی احتمال صریح هر فرضیه، مثل دسته بندی کننده‌ی ساده‌ی بیز<sup>۲</sup>، را محاسبه می‌کنند، این نوع روش‌ها از پر کاربردترین روش‌ها در حل بعضی از مسائل یادگیری هستند. برای مثال، (Michie 1994) تحقیقی در مورد تفاوت‌های دسته بندی کننده‌ی ساده‌ی بیز و دیگر الگوریتم‌های یادگیری، از جمله یادگیری درختی و شبکه‌های عصبی، ارائه می‌کند. این تحقیقات نشان می‌دهد که کارایی دسته بندی کننده‌ی ساده‌ی بیز در بعضی ویژگی‌ها ضعیف‌تر از دیگر الگوریتم‌ها و در بعضی ویژگی‌ها بهتر است. در این فصل دسته بندی کننده‌ی ساده‌ی بیز را به همراه چند مثال بررسی می‌کنیم. در کل، کاربرد این الگوریتم را روی مسئله‌ی دسته بندی متونی مثل مقالات خبری الکترونیک بررسی می‌کنیم. برای چنین کارهای یادگیری‌ای دسته بندی کننده‌ی ساده‌ی بیز یکی از بهترین الگوریتم شناخته شده است.

دلیل دوم اهمیت متد‌های بیز در مطالعه‌ی ما در یادگیری ماشین زمینه‌ی مساعدی است که این متد‌ها برای درک الگوریتم‌های یادگیری‌ای که مستقیماً با احتمالات کار نمی‌کنند ایجاد می‌کند. برای مثال، در این فصل، ما الگوریتم‌هایی چون Find-S و Candidate-Elimination،

---

<sup>1</sup> framework

<sup>2</sup> naive Bayes classifier

را که در فصل ۲ آمده بود، برای مشخص کردن شروطی که خروجی، محتمل‌ترین فرضیه‌ی سازگار با نمونه‌های آموزشی باشد را بررسی خواهیم کرد. همچنین با بررسی‌ای بیزی توجیهی برای یکی از انتخاب‌های کلیدی الگوریتم‌های یادگیری شبکه‌های عصبی (انتخاب تابع خطای مجموع مربعات خطا برای جستجوی فضای شبکه‌های عصبی ممکن) ارائه خواهیم کرد. همچنین در این بخش اشتقاق تابع خطای جایگزینی را محاسبه می‌کنیم، cross-entropy، این معیار زمانی که تابع هدف احتمالات را پیش‌بینی می‌کند از معیار مجموع خطاهای مربعی کارآمدتر است. از نظری بیزی بایاس استقرایی الگوریتم‌های درختی که به درخت‌های کوچک‌تر علاقه دارند و قانون کوتاه‌ترین طول توضیح را بررسی خواهیم کرد. آشنایی پایه‌ای با روش‌های بیزی برای درک بسیاری از الگوریتم‌های یادگیری ماشین اهمیت بسزایی دارد. ویژگی‌های متد‌های یادگیری بیزی شامل موارد زیر است:

- هر نمونه‌ی آموزشی می‌تواند احتمال تخمینی اینکه فرضیه درست است را کم یا زیاد کند. این حقیقت باعث می‌شود که روش‌های بیزی نسبت به الگوریتم‌هایی که کاملاً فرضیه را با نمونه‌های غیر سازگار رد می‌کنند انعطاف‌تر پذیرتر باشند.
- می‌توان از دانش قبلی به همراه داده‌های مشاهده شده برای تعیین احتمال نهایی درستی فرضیه‌ها استفاده کرد. در یادگیری بیزی، دانش قبلی با (۱) احتمال اولیه‌ی هر فرضیه و (۲) توزیع احتمال روی داده‌های تعیین شده برای هر فرضیه‌ی ممکن تعیین می‌شود.
- متد‌های بیزی می‌توانند برای فرضیه‌ها احتمالاتی را پیش‌بینی کنند (برای مثال، فرضیه‌ی "این بیمار ذات‌الریه با احتمال ۹۳٪ کاملاً بهبود خواهد یافت).
- نمونه‌های جدید را می‌توان با ترکیب پیش‌بینی‌های چندین فرضیه، (هر کدام با وزن احتمالشان) دسته‌بندی کرد.
- حتی هنگامی که اثبات می‌شود که متد‌های بیزی محاسباتی غیر قابل پیش‌بینی انجام می‌دهند، با این حال معیار استاندارد برای دیگر متد‌های عملی یادگیری مطرح می‌کنند.

یکی از مشکلات عملی کاربرد متد‌های بیزی نیاز آن‌ها به داشتن دانش اولیه از بسیاری از احتمالات است. هنگامی که این اطلاعات به طور دقیق در دسترس نیست، گاهی آن‌ها را با استفاده از دانش قبلی، داده‌های موجود قبلی، و فرض‌هایی درباره‌ی فرم توزیع تخمین می‌زنیم. دومین مشکل عملی کاربرد این متدها هزینه‌ی محاسباتی قابل توجه آن‌ها برای تعیین فرضیه‌ی بهینه‌ی بیز در حالت کلی است (که رابطه خطی با تعداد فرضیه‌های ممکن دارد). در حالت‌های خاص این هزینه‌ی محاسباتی به طور قابل توجهی کاهش می‌یابد.

ادامه‌ی این فصل به شکل زیر ساختار بندی شده است. بخش ۶.۲ قضیه‌ی بیز را معرفی کرده و محتمل‌ترین<sup>۱</sup> و فرضیه‌ای با حداکثر احتمال ثانویه<sup>۲</sup> را تعریف خواهد کرد. چهار زیربخش این بخش این چارچوب<sup>۳</sup> را برای بررسی چندین مشکل و الگوریتم یادگیری که در فصل‌های گذشته مطرح شد به کار می‌برند. برای مثال، نشان می‌دهیم که چندین الگوریتم مطرح شده با چه فرض‌هایی محتمل‌ترین فرضیه را خروجی می‌دهند. بخش‌های بعدی تعدادی از الگوریتم‌های یادگیری که منحصر با احتمالات کار می‌کنند را معرفی خواهند کرد. این الگوریتم‌ها شامل دسته بندی کننده‌ی بهینه‌ی بیز، الگوریتم گیبز و دسته بندی کننده‌ی ساده‌ی بیز می‌شود. بالاخره درباره‌ی شبکه‌ی باور بیز<sup>۴</sup> بحث خواهیم کرد و روشی جدید برای یادگیری بر اساس استدلال احتمالی و الگوریتم EM که الگوریتمی پرکاربرد در یادگیری در حضور متغیرهای غیر قابل مشاهده است را بررسی خواهیم کرد.

<sup>1</sup> maximum likelihood

<sup>2</sup> maximum a posteriori probability hypotheses

<sup>3</sup> framework

<sup>4</sup> Bayesian belief network

## ۶.۲ قضیه بیز

در یادگیری ماشین، گاهی سعی داریم که از میان فضای فرضیه های  $H$  بهترین فرضیه ی سازگار با نمونه های آموزشی  $D$  را پیدا کنیم. چندین راه برای تعریف "بهترین" در این جمله وجود دارد، یکی از این تعاریف "محتمل ترین" است، با در دست داشتن داده های  $D$  بدون نیاز به هیچ اطلاعات اولیه ی دیگر نمی توان محتمل ترین فرضیه را انتخاب کرد. قضیه ی بیز متدی مستقیم برای محاسبه ی احتمالات فرضیه های موجود در  $H$  ارائه می کند. به عبارت دیگر، قضیه ی بیز روشی برای محاسبه ی احتمال یک فرضیه بر اساس احتمال قبلی اش، احتمال مشاهده ی داده های سازگار با فرض درستی این فرضیه و احتمال خود داده های مشاهده شده ارائه می کند.

برای تعریف دقیق قضیه ی بیز، ابتدا بیا باید نشانه گذاری ها را معرفی کنیم. برای نشان دادن احتمال اولیه ی فرضیه ی  $h$ ، احتمال قبل از مشاهده ی داده های آموزشی، از  $P(h)$  استفاده می کنیم. به  $P(h)$  احتمال اولیه ی  $h$  نیز می گویند، این احتمال از اطلاعات قبلی ای که در مورد احتمال درستی فرضیه ی  $h$  داریم تأثیر می پذیرد. به طور مشابه از  $P(D)$  برای نمایش احتمال اولیه ی مشاهده ی نمونه های آموزشی  $D$  استفاده می کنیم (مثلاً احتمال مشاهده ی  $D$  بدون داشتن هیچ اطلاعات قبلی در مورد اینکه با چه فرضیه هایی سازگار است). برای نشان دادن احتمال مشاهده ی  $D$  در جایی که فرضیه ی  $h$  درست است از  $P(D|h)$  استفاده می کنیم. در حالت کلی، از  $p(x|y)$  برای نشان دادن احتمال  $x$  با فرض وقوع  $y$  استفاده می کنیم. در مسائل یادگیری ماشین، علاقه ی ما به احتمال  $P(h|D)$  است که در آن  $h$  یک فرضیه و  $D$  نمونه های آموزشی مشاهده شده هستند. به  $P(h|D)$  احتمال ثانویه ی  $h$  نیز می گویند، زیرا که اطمینان ما به فرضیه ی  $h$  بعد از مشاهده ی نمونه های آموزشی  $D$  را نشان می دهد. توجه داشته باشید که احتمال ثانویه  $P(h|D)$  بر خلاف احتمال اولیه  $P(h)$  که از نمونه های آموزشی مستقل است، از نمونه های آموزشی  $D$  تأثیر می پذیرد.

قضیه بیز، اساس متد های یادگیری بیز است زیرا که راهی برای محاسبه ی احتمال ثانویه  $P(h|D)$  از  $P(h)$ ،  $P(D)$  و  $P(D|h)$ .

### قضیه بیز:

$$p(h|D) = \frac{p(D|h)P(h)}{p(D)} \quad (6.1)$$

همان طور که انتظار می رود، بر اساس قضیه ی بیز  $P(h|D)$  با افزایش  $P(h)$  و  $P(D|h)$  افزایش می یابد. همچنین منطقی است که  $P(h|D)$ ، با افزایش  $P(D)$  کاهش بیابد، زیرا که هر چه که احتمال مشاهده ی  $D$  به طور مستقل از  $h$  بالا تر رود دیگر  $D$  مدرکی برای درستی  $h$  نخواهد بود.

در بسیاری از مسائل یادگیری، یادگیر مجموعه ی فرضیه هایی مثل  $H$  را در نظر می گیرد و در بین آن ها به دنبال محتمل ترین فرضیه ی  $h \in H$  با توجه به نمونه های آموزشی  $D$  می گردد (یا حداقل یکی از محتمل ترین فرضیه ها). هر کدام از این محتمل ترین، فرضیه با حداکثر

---

<sup>1</sup> prior probability

<sup>2</sup> posterior probability

احتمال ثانویه<sup>۱</sup> یا (MAP) نامیده می‌شود. فرضیه‌های MAP را می‌توان با استفاده از قضیه‌ی بیز برای محاسبه‌ی احتمال ثانویه‌ی هر فرضیه مشخص کرد. به صورت دقیق‌تر، زمانی می‌گوییم که فرضیه‌ی  $h_{MAP}$  یک فرضیه‌ی MAP است که

$$\begin{aligned} h_{MAP} &= \arg \max_{h \in H} P(h|D) \\ &= \arg \max_{h \in H} \frac{P(D|h)P(h)}{P(D)} \\ &= \arg \max_{h \in H} P(h|D) P(h) \end{aligned} \quad (6.2)$$

توجه داشته باشید که مرحله آخر عبارات بالا  $P(D)$  چون ثابتی است و  $h$  بر آن تأثیری ندارد حذف می‌شود.

در بعضی موارد، فرض می‌کنیم که هر فرضیه در  $H$  احتمال اولیه‌ی مساوی‌ای دارد (برای هر  $h_i$  و  $h_j$  در  $H$  داریم که  $P(h_i) = P(h_j)$ ). در این شرایط می‌توان رابطه‌ی ۶.۲ را بیشتر ساده کرد و کافی است که فقط عبارت  $P(D|h)$  را برای پیدا کردن محتمل‌ترین فرضیه در نظر بگیریم.  $P(D|h)$  گاهی محتمل بودن داده‌های  $D$  برای  $h$  نیز نامیده می‌شود و هر فرضیه‌ای که  $P(D|h)$  را ماکزیمم کند (ML)<sup>۲</sup>،  $h_{ML}$  نامیده می‌شود.

$$h_{ML} \equiv \arg \max_{h \in H} P(D|h) \quad (6.3)$$

برای مشخص شدن رابطه با مسائل یادگیری ماشین، ابتدا قضیه‌ی بیز را با توجه به نمونه‌های  $D$  و فضای فرضیه‌ی  $H$  معرفی کردیم. در واقع قضیه‌ی بیز کلی‌تر از آنچه در بالا گفته شد است. از قضیه‌ی بیز می‌توان برای هر زیر مجموعه‌ی  $H$  که ناسازگارند (اشتراک ندارند) استفاده کرد (مثل "آسمان آبی است" و "آسمان آبی نیست"). در این فصل، در اکثر موارد فرض خواهیم کرد که  $H$  فضای فرضیه‌ای که تابع هدف را شامل می‌شود است و  $D$  نمونه‌های آموزشی هستند. در مواقع دیگر فرض می‌کنیم که  $H$  مجموعه‌ی دیگر ناسازگاری با یکدیگر از فرضیه‌هاست و  $D$  نیز مجموعه‌ی دیگری از داده‌هاست.

### ۶.۲.۱ یک مثال

برای تصور قانون بیز، فرض کنید که مسئله‌ای برای تشخیص بیماری داریم، دو فرضیه‌ی ممکن برای بیماری وجود دارد: (۱) بیمار نوع خاصی از سرطان دارد و (۲) بیمار آن نوع سرطان را ندارد. داده‌های موجود یک تست آزمایشگاهی است که دو خروجی ممکن دارد:  $\oplus$  (مثبت) و  $\ominus$  (منفی). دانش قبلی داریم در کل جمعیت حاضر در آزمایش فقط ۰.۰۰۸. این بیماری را دارند. علاوه بر آن نتیجه‌ی آزمایش همیشه قطعی نیست و احتمال خطا وجود دارد. تست آزمایشگاهی در ۹۸٪ مواردی که بیمار بیماری را دارد نتیجه‌ی مثبت درست می‌دهد و در ۹۷٪ مواردی که بیمار بیماری را ندارد نتیجه‌ی منفی درست می‌دهد. در بقیه‌ی موارد آزمایش نتیجه‌ی اشتباه می‌دهد. آنچه در بالا گفته شد را خلاصه‌وار می‌توان به صورت زیر نشان داد:

$$P(cancer) = .008, \quad P(\neg cancer) = .992$$

<sup>1</sup> Maximum A Posteriori

<sup>2</sup> maximum likelihood

$$P(\oplus | cancer) = .98, \quad P(\ominus | \neg cancer) = .02$$

$$P(\oplus | \neg cancer) = .03, \quad P(\ominus | \neg cancer) = .97$$

فرض کنید که بیمار جدیدی پذیرش می‌شود و نتیجه‌ی آزمایش مثبت است. حال با چه احتمالی می‌توان گفت که بیمار سرطان دارد؟ فرضیه با حداکثر احتمال را می‌توان از رابطه‌ی ۶.۲ پیدا کرد:

$$P(\oplus | cancer)P(cancer) = (.98).008 = .0078$$

$$P(\oplus | \neg cancer)P(\neg cancer) = (.03).992 = .0298$$

پس، داریم  $h_{MAP} = \neg cancer$ . احتمال ثانویه‌ی فرضیه‌ها را می‌توان با رساندن مجموع دو احتمال به ۱ پیدا کرد (۲۱).  $P(\oplus | cancer)P(cancer) = \frac{.0078}{.0078 + .0298} = .21$ . این مرحله برای این درست است که قضیه‌ی بیز احتمال‌های ثانویه مجموعه‌ی تمامی داده را بدون اشتراک می‌پوشانند (افراز می‌کنند) بیان می‌کند. با وجود اینکه  $P(\oplus)$  مستقیماً توسط مسئله داده نشده است، اما می‌توان آن را محاسبه کرد زیرا که می‌دانیم مجموع دو احتمال  $P(cancer | \oplus)$  و  $P(\neg cancer | \oplus)$  یک است (هر بیمار یا سرطان دارد یا سرطان ندارد). توجه داشته باشید که احتمال ثانویه‌ی سرطان نسبت به احتمال اولیه‌ی آن به طور قابل توجهی زیاده‌تر است، اما با این حال محتمل‌ترین فرضیه این است که بیمار سرطان ندارد.

همان طور که در مثال بالا نشان داده شد، نتیجه‌ی تأثیر بیز به شدت به احتمال اولیه وابسته است، برای اینکه بتوان قضیه را به طور مستقیم به کار برد باید احتمالات اولیه معلوم باشند. توجه داشته باشید که در این مثال فرضیه‌ها کاملاً پذیرفته شده یا رد شده نیستند بلکه هر کدام با افزایش داده‌های مشاهده شده احتمالی پیدا می‌کنند. فرمول اصلی محاسبه‌ی احتمالات در جدول ۶.۱ خلاصه شده است.

### ۶.۳ قضیه‌ی بیز و یادگیری مفهوم

ارتباط بین قضیه‌ی بیز و مسائل یادگیری مفهوم چیست؟ از آنجایی که قضیه‌ی بیز راهی اصولی برای محاسبه‌ی احتمالات ثانویه‌ی هر یک از فرضیه‌ها بعد از مشاهده‌ی داده‌های آموزشی ارائه می‌کند، می‌توانیم از آن برای پایه‌ی یک الگوریتم یادگیری ساده استفاده کنیم، الگوریتمی که احتمال هر یک از فرضیه‌ها را محاسبه کرده و محتمل‌ترین فرضیه‌ها را خروجی می‌دهد. در این بخش چنین الگوریتم‌های بدون شعور<sup>۱</sup> یادگیری مفهوم بیز را بررسی و با الگوریتم‌های یادگیری مفهوم مقایسه می‌کنیم. همان طور که بعداً نیز خواهیم دید، یکی از نتایج جالب این مقایسه این است که تحت شرایط خاصی چندین الگوریتمی که در فصل‌های گذشته بررسی شدند همان فرضیه‌ای که یادگیری بدون شعور بیز خروجی می‌دهد را خروجی می‌دهند، با این تفاوت که آن‌ها احتمالات فرضیه‌ها را مشخص نمی‌کنند و فقط محتمل‌ترین را مشخص می‌کنند.

- قانون ضرب<sup>۲</sup>: احتمال  $P(A \wedge B)$  که احتمال عطف دو اتفاق  $A$  و  $B$  است را محاسبه کن

$$P(A \wedge B) = P(A | B)P(B) = P(B | A)P(A)$$

- قانون جمع<sup>۱</sup>: احتمال فصل دو اتفاق  $A$  و  $B$  را محاسبه کن

<sup>۱</sup> brute-force

<sup>۲</sup> Product rule

---


$$P(A \vee B) = P(A) + P(B) - P(A \wedge B)$$

- قضیه بیز<sup>۲</sup>: احتمال ثانویه ی  $P(h|D)$  را محاسبه کن

$$P(h|D) = \frac{P(D|h)P(h)}{P(D)}$$

- قضیه ی مجموع احتمالات<sup>۳</sup>: اگر اتفاق های  $A_1, \dots, A_n$  دو به دو ناسازگار باشند و  $\sum_{i=1}^n P(A_i) = 1$  خواهیم داشت

$$P(B) = \sum_{i=1}^n P(B|A_i)P(A_i)$$

---

جدول ۶.۱ خلاصه ی فرمول های پایه ای احتمال.

### ۶.۳.۱ یادگیری مفهوم بدون شعور بیز

مسئله ی یادگیری مفهومی را که در ابتدای فصل ۲ معرفی شد را در نظر بگیرید. در کل، فرض کنید که یادگیر فضای فرضیه ای محدود  $H$  را که شامل فرضیه هایی که بر فضای نمونه ای  $X$  تعریف شده اند است در نظر می گیرد و تابع هدف نیز مفهومی به فرم  $c: X \rightarrow \{0,1\}$  است. مثل معمول، فرض می کنیم که به یادگیر دسته ای از نمونه های آموزشی مثل  $\langle x_1, d_1 \rangle \dots \langle x_m, d_m \rangle$  داده می شود، در این نمونه های آموزشی  $x_i$  عضوی از  $X$  و  $d_i$  نیز مقدار هدف برای آن  $x_i$  است ( $d_i = c(x_i)$ ). برای ساده سازی بحث در این بخش، فرض می کنیم که ترتیب نمونه های نمونه ها  $\langle x_1 \dots x_m \rangle$  ثابت است پس می توان نمونه های آموزشی  $D$  را به فرم ساده به صورت  $D = \langle d_1 \dots d_m \rangle$  نوشت. می توان نشان داد که این ساده نویسی تأثیری بر نتایج بدست آمده از این قسمت ندارد (تمرین ۶.۴).

می توان با استفاده از قضیه ی بیز الگوریتم یادگیری مفهوم مستقیمی طراحی کرد که فرضیه با حداکثر احتمال ثانویه را خروجی دهد:

### الگوریتم یادگیری بدون شعور MAP<sup>۴</sup>

۱. برای هر فرضیه  $h$  در  $H$  احتمال ثانویه را محاسبه کن،

$$p(h|D) = \frac{p(D|h)P(h)}{p(D)}$$

۲. فرضیه  $h_{MAP}$  را که بیشترین احتمال ثانویه را دارد خروجی بده

$$h_{MAP} = \arg \max_{h \in H} P(h|D)$$

---

<sup>1</sup> Sum rule

<sup>2</sup> Bayes theorem

<sup>3</sup> Theorem of total probability

<sup>4</sup> Brute-Force MAP Learning

این الگوریتم ممکن است محاسبات قابل توجهی نیاز داشته باشد، زیرا که قانون بیز را برای تمامی فرضیه های  $H$  برای محاسبه ی  $P(h|D)$  به کار می برد. چنین حجم محاسباتی ای برای فضای فرضیه هایی با اندازه ی بالا غیر عملی است، با این وجود الگوریتم هنوز مورد توجه است زیرا که معیاری ارائه می کند در حالی که دیگر الگوریتم های یادگیری مفهوم هیچ معیاری ارائه نمی کنند.

برای آماده سازی یک مسئله برای حل با الگوریتم یادگیری بدون شعور MAP لازم است که مقادیر  $P(h)$  و  $P(D|h)$  را مشخص کنیم (همان طور که بعداً هم خواهیم دید با مشخص کردن مقادیر ذکر شده مقدار  $P(D)$  نیز مشخص می شود). اطلاعات اولیه ی ما در مورد مسئله با تعیین دو توزیع  $P(h)$  و  $P(D|h)$  به طور دلخواه مشخص می شود. بیا بیا ابتدا با فرض های زیر شروع کنیم :

۱. نمونه های آموزشی  $D$  خطا ندارند ( $d_i = c(x_i)$ )

۲. مفهوم هدف  $C$  در فضای فرضیه ای  $H$  موجود است.

۳. هیچ مدرکی بر برتری یک فرضیه بر فرضیه ی دیگر وجود ندارد.

با فرض های بالا، چه مقداری باید برای  $P(h)$  تعیین شود؟ بدون هیچ اطلاعات قبلی، برتری فرضیه ها بر یکدیگر بی دلیل خواهد بود، می توانیم احتمال تمامی آن ها را مساوی قرار دهیم. علاوه بر آن، چون فرض کرده ایم تابع هدف  $C$  در  $H$  موجود است باید طوری احتمال را پخش کنیم که مجموع احتمال کل  $H$  یک باشد. پس خواهیم داشت:

$$P(h) = \frac{1}{|H|} \text{ for all } h \text{ in } H$$

اما  $P(D|h)$  چه احتمالی باید داشته باشد؟  $P(D|h)$  احتمال مشاهده ی مقادیر هدف  $D = \langle d_1 \dots d_n \rangle$  است که برای دسته ی ثابت نمونه ها زمانی که  $h$  درست است می باشد. (مثلاً زمانی که  $h$  همان مفهوم هدف  $C$  است). از آنجایی که فرض کردیم داده های آموزشی خطا ندارند، احتمال دیدن  $d_i$  اگر  $d_i = h(x_i)$  باشد ۱ و اگر  $d_i \neq h(x_i)$  باشد ۰ است. بنابراین،

$$P(D|h) = \begin{cases} 1 & \text{if } d_i = h(x_i) \text{ for all } d_i \text{ in } D \\ 0 & \text{otherwise} \end{cases} \quad (6.4)$$

به عبارت دیگر احتمال مشاهده ی  $D$  با داشتن  $h$ ، ۱ است اگر  $h$  سازگار باشد و در غیر این صورت ۰ است.

با این نوع انتخاب  $P(h)$  و  $P(D|h)$  حال مسئله را کاملاً برای الگوریتم یادگیری بدون شعور MAP آماده کرده ایم. مرحله ی اول این الگوریتم که در آن با استفاده از قضیه ی بیز احتمال ثانویه ی  $P(h|D)$  برای تمامی  $h$  ها با توجه به نمونه های آموزشی  $D$  محاسبه می شود را در نظر بگیرید. با توجه به قضیه ی بیز داریم،

$$p(h|D) = \frac{p(D|h)P(h)}{p(D)}$$

ابتدا فرض کنید که  $h$  با نمونه های آموزشی ناسازگار است. از رابطه ی ۶.۴ داریم که  $P(D|h)$  صفر است زیرا که  $h$  با  $D$  ناسازگار است پس داریم که:

$$P(h|D) = \frac{0 \cdot P(h)}{P(D)} = 0 \text{ if } h \text{ is inconsistent with } D$$

پس احتمال ثانویه فرضیه‌ی ناسازگار با  $D$  صفر خواهد بود.

حال فرض کنید که فرضیه‌ی  $h$  با  $D$  سازگار است. از رابطه‌ی ۶.۴ داریم که  $P(D|h)$  یک فرض شده است زیرا که  $h$  با  $D$  سازگار است. داریم،

$$\begin{aligned} P(h|D) &= \frac{1 \cdot \frac{1}{|H|}}{P(D)} \\ &= \frac{1 \cdot \frac{1}{|H|}}{\frac{|VS_{H,D}|}{|H|}} \\ &= \frac{1}{|VS_{H,D}|} \text{ if } h \text{ is consistent with } D \end{aligned}$$

در این رابطه  $VS_{H,D}$  زیر مجموعه‌ای از  $H$  است که با  $D$  سازگار است (مثلاً  $VS_{H,D}$  می‌تواند همان فضای ویژه‌ای فصل ۲ باشد که با توجه به  $D$  بدست آمده). تشخیص اینکه  $P(D) = \frac{|VS_{H,D}|}{|H|}$  کار ساده‌ای است زیرا که مجموع  $P(h|D)$  برای تمامی فرضیه‌ها باید ۱ باشد و از طرفی تعداد کل فرضیه‌های سازگار با  $D$  در  $H$  طبق تعریف  $|VS_{H,D}|$  است. می‌توان مقدار  $P(D)$  را از قضیه‌ی مجموع احتمال (در جدول ۶.۱) و این حقیقت که فرضیه‌ها دو به دو ناسازگارند  $((\forall i \neq j)(P(h_i \wedge h_j) = 0))$  بدست آورد.

$$\begin{aligned} P(D) &= \sum_{h_i \in H} P(D|h_i)P(h_i) \\ &= \sum_{h_i \in VS_{H,D}} 1 \cdot \frac{1}{|H|} + \sum_{h_i \notin VS_{H,D}} 0 \cdot \frac{1}{|H|} \\ &= \sum_{h_i \in VS_{H,D}} 1 \cdot \frac{1}{|H|} \\ &= \frac{|VS_{H,D}|}{|H|} \end{aligned}$$

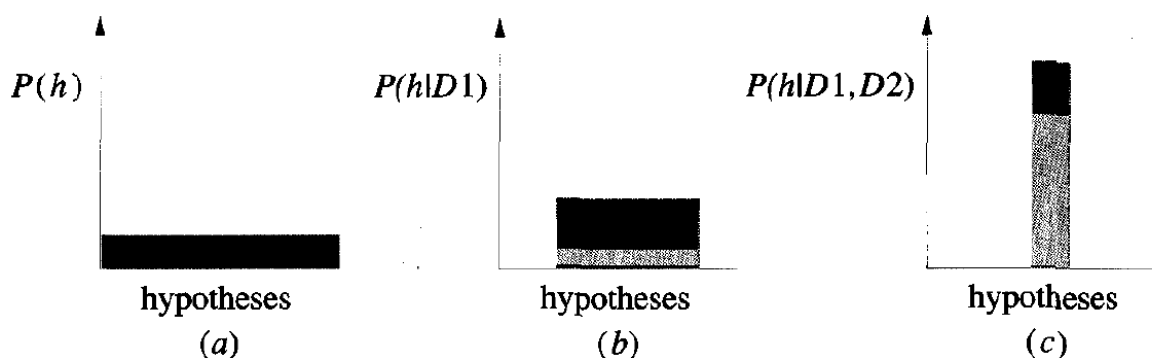
به طور خلاصه اینکه با فرض‌هایی که در مورد  $P(h)$  و  $P(D|h)$  کردیم قضیه‌ی زیر ایجاب می‌کند که  $P(h|D)$  به صورت زیر باشد:

$$P(h|D) = \begin{cases} \frac{1}{|VS_{H,D}|} & \text{if } h \text{ is consistent with } D \\ 0 & \text{otherwise} \end{cases} \quad (6.5)$$



در این رابطه  $|VS_{H,D}|$  تعداد فرضیه های  $H$  که با  $D$  سازگارند است. شکل ۶.۱ سیر تکامل احتمالات را با نمودار نشان می دهد. ابتدا (شکل (a) 6.1) تمامی فرضیه ها احتمال یکسانی دارند. با افزایش داده های آموزشی (شکل های (b) 6.1 و (c) 6.1) احتمال ثانویه ی فرضیه های ناسازگار صفر می شود اما مجموع کل احتمالات ۱ باقی می ماند، یعنی احتمال فرضیه هایی که صفر می شود به طور مساوی در بین فرضیه های دیگر تقسیم می شود.

بررسی بالا نشان داد با انتخاب  $P(h)$  و  $P(D|h)$  تمامی فرضیه های سازگار احتمال ثانویه ی مساوی  $(1/|VS_{H,D}|)$  خواهند داشت و احتمال فرضیه های ناسازگار صفر خواهد شد. پس با توجه به این بررسی هر فرضیه ی سازگار یک MAP (فرضیه با حداکثر احتمال) است.



شکل ۶.۱ تکامل احتمال ثانویه ی  $P(h|D)$  با افزایش داده های آموزشی.  
 (a) اولویت یکسان به تمامی فرضیه ها داده می شود. با افزایش داده ها به  $D1$  (b) و سپس به  $D1/D2$  (c)، احتمال ثانویه ی فرضیه های ناسازگار به صفر می رسد در حالی که احتمال ثانویه برای فرضیه های فضای ویژه افزایش می یابد.

## ۶.۳.۲ فرضیه های MAP و یادگیرهای سازگار

بررسی های بالا نشان می دهد که با مفروضات مذکور تمامی فرضیه های سازگار با  $D$  فرضیه ای MAP هستند. این عبارت را می توان مستقیماً به عبارتی جالب در مورد دسته ای از یادگیرها که یادگیرهای سازگار<sup>۱</sup> می نامیم تفسیر کرد. زمانی می گوییم که یک الگوریتم یادگیری یادگیر سازگار است که فرضیه ی خروجی هیچ خطایی بر روی داده های آموزشی نداشته باشد. بر اساس بررسی بالا، می توان گفت تمامی یادگیرهای سازگار فرضیه ی خروجیشان یک فرضیه ی MAP است، به شرطی که فرض کنیم که توزیع اولیه احتمال روی  $H$  یکنواخت باشد  $((\forall i, j) P(h_i) = P(h_j))$  و همچنین فرض کنیم که داده های آموزشی قطعی و بدون خطا هستند  $P(D|H)=1$  اگر  $D$  با  $h$  سازگار باشد و در غیر این صورت صفر است).

برای مثال، الگوریتم یادگیری مفهوم Find-S را که در فصل ۲ بررسی شد را در نظر بگیرید. Find-S فضای فرضیه ای  $H$  را از فرضیه های جزئی تر به کلی تر جستجو می کند تا جزئی ترین فرضیه ی سازگار را پیدا کند (جزئی ترین عضو فضای ویژه). چون Find-S فرضیه ای سازگار را خروجی می دهد پس طبق احتمالات مفروض بالا برای  $P(h)$  و  $P(D|h)$  فرضیه ای MAP را خروجی خواهد داد. البته Find-S هیچ

<sup>1</sup> consistent learner

احتمالی را محاسبه و ارائه نمی‌کند و فقط خاص‌ترین فرضیه‌ی فضای ویژه را پیدا می‌کند. با این وجود، با مشخص کردن توزیع‌های  $P(h)$  و  $P(D|h)$  به صورتی که فرضیه‌ی خروجی MAP باشد، روشی مفید برای مشخص کردن رفتار Find-S داریم.

آیا توزیع احتمال‌های دیگری برای  $P(h)$  و  $P(D|h)$  وجود دارد که خروجی FIND-S فرضیه‌ی MAP باشد؟ بله، چون FIND-S خاص‌ترین فرضیه‌ی فضای ویژه را پیدا می‌کند فرضیه‌ی خروجی‌اش با اختصاص توزیع احتمال‌هایی که به سمت فرضیه‌های خاص‌تر تمایل دارند MAP خواهد بود. به عبارت دقیق‌تر، فرض کنید که  $\mathcal{H}$  تمامی توزیع احتمال  $P(h)$  روی  $H$  است که در آن‌ها داریم  $P(h_1) \geq P(h_2)$  اگر  $h_1$  خاص‌تر از  $h_2$  باشد. می‌توان نشان داد با چنین توزیع احتمال‌هایی و توزیع احتمال مذکور برای  $P(D|h)$  فرضیه‌ی خروجی FIND-S یک فرضیه‌ی MAP خواهد بود.

خلاصه بحث بالا بدین شکل است، چارچوب بیزی به ما اجازه می‌دهد تا ویژگی‌های رفتاری الگوریتم‌های یادگیری (حتی الگوریتم‌هایی که مقدار احتمال فرضیه را مشخص نمی‌کنند، مثل FIND-S) را مشخص کنیم. با مشخص کردن توزیع احتمال‌های  $P(h)$  و  $P(D|h)$  به صورتی که فرضیه‌ی خروجی الگوریتم بهینه، MAP، شود، پیش فرض‌هایی که الگوریتم برای نتیجه‌گیری انجام می‌دهد را می‌توان پیدا کرد.

استفاده از دیدگاه بیزی برای بررسی ویژگی‌های الگوریتم‌های یادگیری بدین صورت عملاً مشابه بررسی بایاس استقرایی یادگیرهاست. در فصل ۲ ما بایاس استقرایی یک الگوریتم را دسته‌بندی پیش فرض‌هایی مثل B تعریف کردیم که نحوه‌ی استقرای یادگیر را توجیه می‌کند. برای مثال، گفته شد که بایاس استقرایی الگوریتم Candidate-Elimination وجود مفهوم هدف C در مجموعه‌ی فرضیه‌ی H است. علاوه بر آن نشان دادیم که خروجی این الگوریتم یادگیری را می‌توان از ورودی‌هایش و این پیش فرض استقرایی ضمنی نتیجه گرفت. تفسیری بیزی بالا می‌تواند جایگزینی برای بررسی ویژگی‌های این پیش فرض‌های الگوریتم‌های یادگیری باشد. با این تفاوت که در اینجا به جای مدل کردن الگوریتم با یک سیستم معادل استقرایی، الگوریتم را با سیستم معادل استدلال احتمالی<sup>۱</sup> که بر اساس قضیه‌ی بیز کار می‌کند، مدل سازی می‌کنیم. و در اینجا پیش فرض‌هایی که یادگیر فرض می‌کند به فرم "احتمال اولیه‌های فرضیه‌ها  $P(h)$  و قدرت داده‌ها در قبول یا رد فرضیه‌ها  $P(D|h)$ " است. تعریف  $P(h)$  و  $P(D|h)$  که در این قسمت معرفی شد مربوط به دو الگوریتم Candidate-Elimination و FIND-S بود. سیستم استدلال احتمالی‌ای که بر اساس قضیه‌ی بیز کار می‌کند، با این توزیع‌ها در ورودی و خروجی رفتاری مشابه این الگوریتم‌ها از خود نشان خواهد داد.

بحثی که در این بخش انجام شد حالت خاصی از استدلال بیزی بود زیرا که فرض کردیم داده‌های آموزشی بدون خطایند و فرضیه‌ها نیز قطعی‌اند، یعنی  $P(D|h)$  حتماً یکی از دو مقدار ۱ یا ۰ را دارد. همان طور که در قسمت بعدی نیز خواهیم دید، می‌توان یادگیری از نمونه‌های آموزشی خطا دار را شبیه سازی کرد، فقط کافی است که مقدار  $P(D|h)$  مقادیری غیر ۰ و ۱ را نیز داشته باشد، با این تغییر توزیع احتمال  $P(D|h)$  خطا را کنترل خواهد کرد.

---

<sup>1</sup> probabilistic reasoning system

## ۶.۴ محتمل ترین فرضیه‌ها<sup>۱</sup> و فرضیه‌هایی که کمترین خطای مربعی<sup>۲</sup> را دارند

همان طور که در بالا نیز نشان داده شد تحت شرایطی یک الگوریتم یادگیری فرضیه های MAP را خروجی می‌دهد حتی اگر این الگوریتم از روش بیز یا حتی از محاسبه‌ی احتمال‌ها استفاده نکند.

در این بخش، به مسئله‌ی یادگیری توابع هدف پیوسته مقدار می‌پردازیم، مسئله‌ی که راه‌های زیادی برای آن مثل شبکه‌های عصبی، تقریب خطی، و تقریب چند جمله‌ای ارائه شده است. یک بررسی مستقیم بیزی نشان می‌دهد که در شرایط خاصی هر الگوریتم یادگیری که خطای مربعی بین تخمین و خروجی داده‌های آموزشی را مینیمم کند یک محتمل ترین فرضیه<sup>۳</sup> را خروجی می‌دهد. اهمیت این نتیجه در استفاده از این استدلال بیزی (تحت شرایط خاص) برای توجیه بسیاری از شبکه‌های عصبی و دیگر متدهایی که مجموع خطای مربعی را مینیمم می‌کنند است.

شرایط مسئله‌ی یادگیری تابع هدف پیوسته را در نظر بگیرید، یادگیر  $L$  که از فضای نمونه‌ی  $X$  و فضای فرضیه‌ی  $H$  که مجموعه‌ی  $\mathcal{H}$  از توابع حقیقی مقدار روی نمونه‌های  $X$  استفاده می‌کند (هر  $h$  در  $H$  تابعی است به فرم  $h: X \rightarrow \mathbb{R}$ ، که در آن  $\mathbb{R}$  مجموعه‌ی اعداد حقیقی است). مسئله‌ی  $L$  با آن مواجه است یادگیری تابع هدف مجهول  $f: X \rightarrow \mathbb{R}$  از مجموعه‌ی فرضیه‌های  $H$  است. مجموعه‌ی  $m$  از نمونه‌ی آموزشی در دسترس است، در این مجموعه مقدار تابع هدف هر یک از نمونه‌ها با یک مقدار تصادفی خطا که توزیع نرمال دارد معلوم است. به عبارت دقیق‌تر، هر نمونه‌ی آموزشی زوج مرتبی به فرم  $\langle x_i, d_i \rangle$  است که در آن  $d_i = f(x_i) + e_i$ . در اینجا  $f(x_i)$  خود تابع هدف و مقدار  $e_i$  متغیر تصادفی خطاست. فرض می‌شود که مقدار  $e_i$  مستقل و دارای توزیع نرمال با میانگین صفر است. هدف یادگیر نیز پیدا کردن محتمل ترین فرضیه، یا به صورت معادل، یک فرضیه‌ی MAP است با این فرض که تمامی فرضیه‌ها احتمال اولیه‌ی یکسانی دارند.


با وجود اینکه بررسی‌هایمان را برای یادگیری توابع دلخواه حقیقی مقدار انجام می‌دهیم، مسئله‌ی یادگیری تابع خطی نمونه‌ای از چنین مسائلی است. شکل ۶.۲ شکل تابع هدف خطی  $f$  را به همراه چندین نمونه‌ی آموزشی نشان داده است. خط چین فرضیه‌ی  $h_{ML}$  است که کمترین خطای مربعی را دارد، پس محتمل ترین فرضیه است. توجه داشته باشید که محتمل ترین فرضیه حتماً فرضیه‌ی درست نیست، زیرا که مجموعه‌های آموزشی محدود و خطا دار هستند.

---

<sup>1</sup> maximum likelihood

<sup>2</sup> least squared error

<sup>3</sup> maximum likelihood



شکل ۶.۲ یادگیری تابع حقیقی مقدار.

تابع هدف  $f$  با خط نشان داده شده است. نمونه های آموزشی  $\langle x_i, d_i \rangle$  با فرض اینکه خطایی با توزیع نرمال با میانگین صفر دارند در نظر گرفته شده اند. خط چین تابعی خطی را نشان می دهد که میزان خطای مربعی را مینیمم می کند. بنابراین این فرضیه محتمل ترین فرضیه،  $h_{ML}$ ، بر اساس ۵ نمونه ی آموزشی موجود است.

قبل از اینکه به اثبات محتمل ترین بودن فرضیه هایی که خطای مربعی را مینیمم می کنند در شرایط مذکور بپردازیم؛ ابتدا بیایید دو مفهوم را از تئوری احتمال مرور کنیم: چگالی احتمال و توزیع نرمال. ابتدا برای بحث روی متغیر های تصادفی پیوسته مثل  $e$ ، ابتدا باید چگالی احتمال را معرفی کنیم. دلیل اولیه این پیش زمینه ها این است که می خواهیم مجموع احتمالات روی تمامی مقادیر ممکن متغیر تصادفی یک باشد. در این حالت که متغیر های تصادفی پیوسته هستند، تعیین احتمال را نمی توان با نسبت دادن یک احتمال به هر یک از مقادیر ممکن متغیر تصادفی انجام داد. به جای آن، از چگالی احتمال<sup>۱</sup> برای مقادیر تصادفی حقیقی مثل  $e$  استفاده می کنیم و انتگرال روی کل چگالی احتمال را مساوی یک قرار می دهیم. در کل از حرف کوچک  $p$  برای نشان دادن تابع چگالی احتمال استفاده می کنیم و احتمال را با حرف بزرگ  $P$  نشان می دهیم (گاهی اوقات این مقدار جرم احتمال<sup>۲</sup> نیز نامیده می شود). چگالی احتمال  $p(x_0)$ ،  $\frac{1}{\epsilon}$  برابر مقدار احتمال اینکه متغیر تصادفی در بازه ای  $[x_0, x_0 + \epsilon)$  زمانی که  $\epsilon \rightarrow 0$  قرار بگیرد است.

### چگالی احتمال:

$$p(x_0) \equiv \lim_{\epsilon \rightarrow 0} \frac{1}{\epsilon} P(x_0 \leq x < x_0 + \epsilon)$$

<sup>1</sup> probability density

<sup>2</sup> probability mass

دوم اینکه  $e$  را در مسئله طوری تعریف کردیم که از توزیع احتمال نرمال پیروی می‌کند. توزیع احتمال نرمال، توزیع احتمالی هموار و زنگی شکل است که می‌توان آن را با میانگین  $\mu$  و انحراف معیار  $\sigma$  کاملاً مشخص کرد. برای تعریف دقیق‌تر به جدول ۵.۴ مراجعه کنید.

حال با داشتن این پیش زمینه‌ها می‌توانیم به موضوع اصلی برگردیم: در شرایط مذکور، نشان می‌دهیم که فرضیه‌هایی که خطای مربعی را مینیمم می‌کنند در واقع همان محتمل‌ترین فرضیه‌ها هستند. ابتدا محتمل‌ترین تابع را با استفاده از رابطه‌ی 6.3 مشخص می‌کنیم، با این تفاوت که توزیع احتمال در این رابطه را با  $p$  نشان می‌دهیم.

$$h_{ML} = \arg \max_{h \in H} p(D|h)$$

مثل قبل، فرض می‌کنیم که مجموعه‌ای از نمونه‌های آموزشی مثل  $\langle x_1 \dots x_n \rangle$  با مقدار تابع هدفشان  $D$ ،  $D = \langle d_1 \dots d_2 \rangle$  داریم. در اینجا  $d_i = f(x_i) + e_i$ . با فرض اینکه نمونه‌های آموزشی کاملاً مستقل از فرضیه‌ی  $h$  هستند  $P(D|h)$  را می‌توان بر حسب  $p(d_i|h)$  ها نوشت

$$h_{ML} = \arg \max_{h \in H} \prod_{i=1}^m p(d_i|h)$$

با دانستن اینکه  $e_i$  ها از توزیع نرمال با میانگین صفر و واریانس مجهول  $\sigma^2$  پیروی می‌کنند، هر  $d_i$  نیز باید از توزیع نرمالی با واریانس  $\sigma^2$  و میانگین  $f(x_i)$ ، به جای صفر، پیروی کند. بنابراین  $p(d_i|h)$  را می‌توان به صورت توزیع نرمالی با واریانس  $\sigma^2$  و میانگین  $\mu = f(x_i)$  نوشت. بیایید فرمول این توزیع نرمال را که  $p(d_i|h)$  را توصیف می‌کند بنویسیم، ابتدا فرمولی که در جدول ۵.۴ آمده را می‌نویسیم و مقادیر  $\mu$  و  $\sigma^2$  را جایگزین می‌کنیم. چون رابطه‌ای برای  $d_i$  با فرض اینکه فرضیه‌ی  $h$  توصیف درست از تابع هدف  $f$  است می‌نویسیم، خواهیم داشت که  $\mu = f(x_i) = h(x_i)$

$$\begin{aligned} h_{ML} &= \arg \max_{h \in H} \prod_{i=1}^m \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{1}{2\sigma^2}(d_i-\mu)^2} \\ &= \arg \max_{h \in H} \prod_{i=1}^m \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{1}{2\sigma^2}(d_i-h(x_i))^2} \end{aligned}$$

حال از تبدیلی استفاده می‌کنیم که در اکثر محاسبات محتمل‌ترین‌ها متداول است: به جای ماکزیمم کردن مقدار کل عبارت، لگاریتم آن را که بسیار ساده‌تر است ماکزیمم می‌کنیم. زیرا که تابع  $\ln p$  تابعی یکنواخت و صعودی از  $p$  است. بنابراین ماکزیمم کردن  $\ln p$  باعث ماکزیمم شدن خود  $p$  می‌شود.

$$h_{ML} = \arg \max_{h \in H} \sum_{i=1}^m \ln \frac{1}{\sqrt{2\pi\sigma^2}} - \frac{1}{2\sigma^2} (d_i - h(x_i))^2$$

جمله‌ی اول مستقل از  $h$  است و بنابراین می‌توان آن را حذف کرد،

$$h_{ML} = \arg \max_{h \in H} \sum_{i=1}^m -\frac{1}{2\sigma^2} (d_i - h(x_i))^2$$

ماکزیم کردن این کمیت منفی مشابه مینیم کردن مقدار مثبت آن است،

$$h_{ML} = \arg \min_{h \in H} \sum_{i=1}^m \frac{1}{2\sigma^2} (d_i - h(x_i))^2$$

و دوباره می‌توان ثابتی که مستقل از  $h$  است را حذف کرد و داریم:

$$h_{ML} = \arg \min_{h \in H} \sum_{i=1}^m (d_i - h(x_i))^2 \quad (6.6)$$

رابطه‌ی ۶.۶ نشان می‌دهد که محتمل‌ترین فرضیه  $h_{ML}$  فرضیه‌ای است که مجموع خطاهای مربعی بین مقادیر هدف نمونه‌های آموزشی  $d_i$  و پیش‌بینی فرضیه  $h(x_i)$  را مینیمم کند. این نتیجه‌گیری‌ها با این فرض بود که نمونه‌های آموزشی،  $d_i$  ها، مقادیر تابع هدف به اضافه‌ی مقدار خطای تصادفی با توزیع نرمال و میانگین صفر هستند. همان‌طور که استخراج عبارت بالا نیز نشان می‌دهد، مقدار جمله‌ی مربعی خطای  $(d_i - h(x_i))^2$  مستقیماً از توزیع نرمال ناشی شده است. با استفاده از دیگر توزیع‌های خطا می‌توان تعریف‌های دیگری برای خطا بدست آورد.

توجه داشته باشید که ساختار اشتقاق بالا شامل انتخاب فرضیه‌ای که لگاریتم محتمل بودن  $(\ln p(D|h))$  را حداکثر می‌کند به عنوان محتمل‌ترین فرضیه نیز می‌شود. همان‌طور که پیش‌تر نیز گفته شد، این مشابه این است که محتمل بودن  $(\ln p(D|h))$  را حداکثر کنیم. این روش کار با لگاریتم محتمل بودن<sup>۱</sup> در بسیار از بررسی‌های بیزی مورد استفاده قرار می‌گیرد، زیرا که کار با لگاریتم محتمل بودن بسیار ساده‌تر از کار با خود محتمل بودن است. البته، همان‌طور که قبلاً هم گفته شد، محتمل‌ترین فرضیه همیشه فرضیه‌ی  $MAP$  نیست مگر اینکه احتمال اولیه‌ی تمامی فرضیه‌ها مساوی فرض شود.

چرا استفاده از توزیع نرمال برای مدل‌سازی نویز یا همان خطای نمونه‌ها استفاده می‌کنیم؟ یکی از دلایلی که لازم است حتماً ذکر شود، این است که بررسی را از نظر ریاضی بسیار ساده‌تر می‌کند. دلیل دوم این است که این توزیع توزیعی هموار است و توزیع‌های زنگی شکل تخمین خوبی برای بسیاری از انواع خطاها در سیستم‌های فیزیکی هستند. در واقع، طبق قضیه‌ی حد مرکزی که در فصل ۵ توضیح داده شد، مجموع تعداد زیادی از متغیرهای مستقل و هم‌توزیع بدون توجه به نوع توزیع از توزیع نرمال پیروی می‌کند. این ثابت می‌کند که خطا که خود از مجموع تعداد زیادی متغیر مستقل و با ضریب توزیع یکسان تولید می‌شود از توزیع نرمال پیروی خواهد می‌کند. البته در واقعیت، مؤلفه‌های مختلفی که در نویز تأثیر گذارند همگی از یک توزیع پیروی نمی‌کنند، که در این شرایط این قضیه توجیهی برای استفاده از این توزیع نیست.

---

<sup>1</sup> likelihood

مینیم کردن مجموع خطای مربعی روشی متداول در بسیاری از شبکه های عصبی، منحنی های تخمین و ... در تخمین توابع حقیقی مقدار است. فصل ۴ روش شیب نزول را که مینیم کردن خطای مربعی در شبکه های عصبی را با آن انجام می دهیم مفصلاً توضیح داده است.

بد نیست که قبل از اتمام بحث رابطه ی بین محتمل ترین فرضیه و فرضیه ای که خطای مربعی را مینیم می کند، بعضی محدودیت ها این شرایط مسئله را ذکر کنیم. بررسی بالا فقط خطا در تابع هدف نمونه های آموزشی در نظر گرفته شده است و از خطای خود ویژگی هایی که نمونه را توصیف می کنند صرف نظر شده بود. برای مثال، اگر مسئله یادگیری پیش بینی وزن افراد بر اساس سن و قدشان باشد، در شرایط ذکر شده فقط می توان خطا را برای وزن در نظر گرفت و مقادیر سن و قد دقیق فرض می شوند. بررسی زمانی پیچیده تر می شود که فرض های ساده کننده حذف شوند.

## ۶.۵ محتمل ترین فرضیه برای مسائل پیش بینی

در تعریف مسئله ی قسمت قبلی محتمل ترین فرضیه را فرضیه ای مشخص کردیم که مجموع خطای مربعی را بر روی نمونه های آموزشی مینیم می کند. در این بخش معیاری مشابه برای تعریف مسئله ی دیگری که در شبکه های عصبی متداول است بیان می کنیم: یادگیری پیش بینی احتمالات.

حالتی را در نظر بگیرید که در آن می خواهیم تابعی غیر قطعی (احتمالی)  $f: X \rightarrow \{0,1\}$  را یاد بگیریم که دو خروجی گسسته دارد. برای مثال، فضای نمونه ای  $X$  ممکن است توصیف بیماران با علائم بیماریشان باشد، و تابع هدف  $f(x)$  زمانی که بیمار زنده بماند ۱ و در غیر این صورت ۰ باشد. یا به طور مشابه  $X$  می تواند توصیف مراجعین دریافت وام با وضعیت حسابشان در گذشته باشد و  $f(x)$  زمانی که وام بعدی کامل پرداخت می شود ۱ و در غیر این صورت ۰ باشد. برای مثال، در مجموعه ای از بیماران که علائم مشترکی دارند ۹۲٪ درصد زنده می مانند و ۸٪ جان سالم به در نمی برند. این عدم قطعیت ممکن است ناشی از ناتوانی ما را در مشاهده ی تمامی علائم مهم بیمار باشد یا ممکن است ناشی از یک فرایند تصادفی در پیشرفت بیماری باشد. جدا از اینکه منشأ مشکل چیست، ما تابع هدف  $f(x)$  را داریم که به صورت احتمالی روی این ورودی عمل می کند.

با این تعریف مسئله ممکن است از یک شبکه ی عصبی (یا تخمین زنده ی توابع حقیقی مقدار دیگر) که خروجی اش احتمال  $f(x)=1$  باشد استفاده کنیم. به عبارت دیگر، ما دنبال یادگیری تابع هدف  $f': X \rightarrow [0,1]$  هستیم که در آن  $f'(x)=P(f(x)=1)$ . در مثال بالا، اگر آن علائم غیر قابل تمیز را داشته باشیم به احتمال ۹۲٪ بیمار زنده می ماند، پس  $f'(x)=0.92$  که یعنی احتمال اینکه  $f(x)$  برابر با ۱ باشد ۹۲٪ است، و احتمال اینکه  $f(x)$  برابر با ۰ باشد، ۸٪ است.

چگونه می توان  $f'$  را با روشی مثل شبکه های عصبی یاد گرفت؟ یکی از راه های غیر هوشمندانه جمع کردن تعداد تکرار ۱ ها و ۰ های تابع برای هر نمونه ی ممکن  $x$  و آموزش شبکه ی عصبی با نسبت این تعداد تکرارهاست. همان طور که در ادامه نیز خواهیم دید، به جای این کار می توان از خود نمونه های آموزشی  $f$  برای آموزش شبکه ی عصبی استفاده کرد و محتمل ترین فرضیه برای  $f'$  را بدست آورد.

چه معیاری را بهینه می کنیم تا محتمل ترین فرضیه در این تعریف مسئله را بیابیم؟ برای جواب این سؤال ابتدا باید رابطه ای برای  $P(D|h)$  پیدا کنیم. بیایید فرض کنیم که نمونه های آموزش  $D$  به فرم  $D = \{ \langle x_1, d_1 \rangle \dots \langle x_m, d_m \rangle \}$  هستند که در آن  $d_i$  ها مقدار مشاهده شده ی  $f(x_i)$  است.

با توجه به آنچه درباره‌ی محتمل‌ترین فرضیه گفته شد، مینیمم خطای مربعی قسمت قبل، فرض کردیم که نمونه‌های  $\langle x_1 \dots x_m \rangle$  ثابتند. تا بتوان داده‌ها را فقط با مقدار هدفشان،  $d_i$  بررسی کرد. با وجود اینکه می‌توانستیم فرض دیگری در این تعریف مسئله‌ی جدید داشته باشیم، بیاید با همین فرض قبلی ادامه دهیم تا نشان دهیم این چنین فرض‌هایی در نتیجه‌ی حاصل اثری ندارند. بنابراین فرض می‌کنیم که  $x_i$  و  $d_i$  متغیرهای تصادفی هستند و هر نمونه‌ی آموزشی مستقل ایجاد شده است پس می‌توانیم  $P(D|h)$  را به صورت زیر بنویسیم:

$$P(D|h) = \prod_{i=1}^m P(x_i, d_i|h) \quad (6.7)$$

باز هم فرض می‌کنیم که احتمال مواجهه با هر نمونه مثل  $x_i$  مستقل از  $h$  است. برای مثال، احتمال اینکه در مجموعه‌ی آموزشی بیمار  $x_i$  را داشته باشیم مستقل از فرضیه‌ی ما درباره‌ی احتمال زنده ماندن است (با این وجود البته احتمال زنده ماندن  $d_i$  خیلی به  $h$  مربوط نیست، ارتباط بین مجموعه‌ی آموزشی و فرضیه انکار ناشدنی است). زمانی که  $x$  از  $h$  مستقل باشد می‌توانیم رابطه‌ی بالا به رابطه‌ی زیر ساده کنیم، (با استفاده از قانون جدول ۶.۱)،

$$P(D|h) = \prod_{i=1}^m P(x_i, d_i|h) = \prod_{i=1}^m P(d_i|h, x_i)P(x_i) \quad (6.8)$$

حال احتمال  $P(d_i|h, x_i)$  یا احتمال مشاهده‌ی  $d_i = 1$  برای تک نمونه‌ی  $x_i$  با فرض اینکه فرضیه‌ی  $h$  درست است چیست؟ با توجه به اینکه  $h$  فرضیه‌ی ما از تابع هدفی است که احتمالات را محاسبه می‌کند،  $P(d_i = 1|h, x_i) = h(x_i)$  و در کل،

$$P(d_i|h, x_i) = \begin{cases} h(x_i) & \text{if } d_i = 1 \\ (1 - h(x_i)) & \text{if } d_i = 0 \end{cases} \quad (6.9)$$

برای جایگزینی این رابطه در رابطه‌ی ۶.۸ برای  $P(D|h)$  بیاید ابتدا این رابطه را به فرم ریاضی‌وار تری بنویسیم،

$$P(d_i|h, x_i) = h(x_i)^{d_i} (1 - h(x_i))^{1-d_i} \quad (6.10)$$

به سادگی می‌توان نشان داد که دو رابطه‌ی ۶.۹ و ۶.۱۰ هم ارزند. توجه داشته باشید که زمانی که  $d_i = 1$  عبارت دوم رابطه‌ی ۶.۱۰  $(1 - h(x_i))^{1-d_i}$  مساوی یک می‌شود بنابراین خواهیم داشت که  $P(d_i = 1|h, x_i) = h(x_i)^{d_i}$  که هم ارز حالت اول رابطه‌ی ۶.۹ است، به طور مشابه می‌توان نشان داد که برای  $d_i = 0$  نیز دو رابطه با هم، هم ارزند.

می‌توان از رابطه‌ی ۶.۱۰ برای جایگزینی  $P(d_i|h, x_i)$  در رابطه‌ی ۶.۸ استفاده کرد،

$$P(D|h) = \prod_{i=1}^m h(x_i)^{d_i} (1 - h(x_i))^{1-d_i} P(x_i) \quad (6.11)$$

حال می‌توانیم رابطه‌ی محتمل‌ترین فرضیه را بنویسیم،



$$h_{ML} = \arg \max_{h \in H} \prod_{i=1}^m h(x_i)^{d_i} (1 - h(x_i))^{1-d_i} P(x_i)$$

جمله‌ی آخری مستقل از  $h$  است و می‌توان آن را حذف کرد،

$$h_{ML} = \arg \max_{h \in H} \prod_{i=1}^m h(x_i)^{d_i} (1 - h(x_i))^{1-d_i} \quad (6.12)$$

عبارت سمت راست رابطه‌ی ۶.۱۲ را می‌توان در تعمیم توزیع دو جمله‌ای در جدول ۵.۳ دید. عبارت رابطه‌ی 6.12 احتمال ظهور برآمد  $< d_1 \dots d_m >$  را با فرض اینکه هر سکه‌ی  $x_i$  احتمال شیر آمدن  $h(x_i)$  را داشته باشد را نشان می‌دهد. توجه داشته باشید که توزیع دو جمله‌ای که در جدول ۵.۳ آمد مشابه این رابطه است، اما فرض دیگری نیز دارد، احتمال شیر آمدن برای تمامی سکه‌ها را مساوی فرض می‌کند  $(h(x_i) = h(x_j), \forall i, j)$ . اما در هر دو حالت فرض می‌کنیم که برآمد پرتاب سکه‌ها ناسازگارند، فرضی که در تعریف مسئله فعلی ما نیز صدق می‌کند.

مشابه گذشته، کار با لگاریتم محتمل بودن راحت‌تر از خود محتمل بودن است پس داریم:

$$h_{ML} = \arg \max_{h \in H} \sum_{i=1}^m d_i \ln h(x_i) + (1 - d_i) \ln(1 - h(x_i)) \quad (6.13)$$

رابطه‌ی ۶.۱۳ کمیتی را نشان می‌دهد که برای پیدا کردن محتمل‌ترین فرضیه در تعریف مسئله‌ی فعلی ماکزیمم می‌کنیم. این نتیجه مشابه نتیجه‌ی قبلی ما در مینیمم کردن مجموع خطای مربعی محتمل‌ترین فرضیه در تعریف مسئله‌ی قبلی است. به شباهت بین رابطه‌ی 6.13 و فرم کلی تابع آنتروپی  $-\sum_i p_i \log p_i$  که در فصل ۳ آمد توجه کنید. بخاطر این شباهت، قرینه‌ی عبارت بالا گاهی آنتروپی دورگه<sup>۱</sup> نامیده می‌شود.

### ۶.۵.۱ شیب نزول برای پیدا کردن محتمل‌ترین فرضیه در یک شبکه‌ی عصبی

در بالا نشان دادیم که با ماکزیمم کردن کمیت رابطه‌ی ۶.۱۳ محتمل‌ترین فرضیه بدست خواهد آمد. بیایید این کمیت را با اختصار  $G(h, D)$  نشان دهیم. در این بخش قانونی برای آموزش وزن‌ها<sup>۲</sup> برای شبکه‌های عصبی بدست خواهیم آورد که  $G(h, D)$  را توسط روش شیب نزول ماکزیمم می‌کند.

همان طور که در فصل ۴ نیز بحث شد، گرادیان  $G(h, D)$  توسط بردار مشتق‌های جزئی  $G(h, D)$  نسبت به وزن‌های مختلف شبکه که فرضیه‌ی  $h$  را مشخص می‌کند ایجاد می‌شود (برای توضیح کامل درباره‌ی جزئیات جستجوی شیب نزول و واژگان بکار رفته به فصل ۴ مراجعه کنید). در این قسمت، مشتق جزئی  $G(h, D)$  نسبت به وزن  $w_{jk}$  که از واحد  $k$  ام به واحد  $j$  ام است به فرم زیر است:

<sup>1</sup> cross entropy

<sup>2</sup> weight training

$$\begin{aligned}
\frac{\partial G(h, D)}{\partial w_{jk}} &= \sum_{i=1}^m \frac{\partial G(h, D)}{\partial h(x_i)} \frac{\partial h(x_i)}{\partial w_{jk}} \\
&= \sum_{i=1}^m \frac{\partial (d_i \ln h(x_i) + (1 - d_i) \ln(1 - h(x_i)))}{\partial h(x_i)} \frac{\partial h(x_i)}{\partial w_{jk}} \\
&= \sum_{i=1}^m \frac{d_i - h(x_i)}{\partial h(x_i)(1 - h(x_i))} \frac{\partial h(x_i)}{\partial w_{jk}}
\end{aligned} \tag{6.14}$$

برای ساده نگه داشتن محاسبات، فرض کنید که شبکه‌ی عصبی ما از یک لایه واحد سیگموئید تشکیل شده و در این حالت داریم که

$$\frac{\partial h(x_i)}{\partial w_{jk}} = \sigma'(x') x_{ijk} = h(x_i)(1 - h(x_i)) x_{ijk}$$

در این رابطه  $x_{ijk}$  k امین ورودی به واحد j برای i امین نمونه‌ی آموزشی است، و  $\sigma'(x)$  مشتق تابع سیگموئید است (به فصل ۴ رجوع کنید).  
 بالاخره، این رابطه را در رابطه‌ی ۶.۱۴ جایگذاری می‌کنیم و رابطه‌ی ای برای مؤلفه‌های گرادیان بدست می‌آوریم،

$$\frac{\partial G(h, D)}{\partial w_{jk}} = \sum_{i=1}^m (d_i - h(x_i)) x_{ijk}$$

چون بیشتر به دنبال ماکزیمم  $P(D|h)$  هستیم تا مینیمم به جای شیب نزول از جستجوی شیب صعود<sup>۱</sup> استفاده می‌کنیم. در هر حلقه جستجو بردار توسط قانون زیر به سمت گرادیان تصحیح می‌شود.

$$w_{jk} \leftarrow w_{jk} + \Delta w_{jk}$$

که داریم،

$$\Delta w_{jk} = \eta \sum_{i=1}^m (d_i - h(x_i)) x_{ijk} \tag{6.15}$$

و در این رابطه نیز  $\eta$  مقدار کوچک و مثبت است که اندازه‌ی قدم‌ها در جستجوی شیب صعود را مشخص می‌کند.

جالب است که این قانون تغییر وزن‌ها را با قانون تغییر وزن الگوریتم Backpropagation که مجموع خطای مربعی بین پیش بینی و مقدار اصلی را مینیمم می‌کرد مقایسه کنیم. قانون تغییر وزن برای واحد‌های خروجی در Backpropagation با نشانه گذاری این فصل به شکل زیر است،

$$w_{jk} \leftarrow w_{jk} + \Delta w_{jk}$$

---

<sup>1</sup> gradient ascent

که در آن

$$\Delta w_{jk} = \eta \sum_{i=1}^m h(x_i)(1 - h(x_i))(d_i - h(x_i))x_{ijk}$$

توجه دارید که این رابطه جز در جمله‌ی  $h(x_i)(1 - h(x_i))$  که از تابع سیگموئید ناشی شده کاملاً شبیه رابطه‌ی ۶.۱۵ است.

خلاصه اینکه، این دو قانون تغییر وزن هر دو در تعریف مسئله‌ی خودشان به سمت محتمل‌ترین فرضیه همگرا می‌شوند. قانونی که مجموع خطا‌های مربعی را مینیمم می‌کند با فرض اینکه خطا‌های داده‌های آموزشی را می‌توان با توزیع نرمال مدل سازی کرد به دنبال محتمل‌ترین فرضیه می‌گردد. قانونی که آنتروپی دورگه را مینیمم می‌کند با فرض اینکه مقادیر منطقی مشاهده شده احتمالی (و نه قطعی) هستند به دنبال محتمل‌ترین فرضیه برای تابع پیش بینی احتمال بر حسب نمونه‌ها می‌گردد.

## ۶.۶ قانون کمترین طول توضیح<sup>۱</sup>

با توجه به آنچه در فصل ۳ درباره‌ی تیغ Ocam گفته شد، یک بایاس استقرایی متداول، به فرم "توضیحی که کوتاه تر است را در مورد داده‌های مشاهده شده قبول کن" است. در آن فصل درباره‌ی ضررهای توضیحات بلند با توجه به تیغ Ocam استدلال کردیم. در اینجا با دیدی بیزی به این موضوع می‌پردازیم و قانونی مشابه به نام قانون کمترین طول توضیح (MDL) را بررسی خواهیم کرد.

انگیزه‌ی ایجاد قانون کمترین طول توضیح تفسیر تعریف  $h_{MAP}$  با مفاهیم اولیه‌ی تئوری اطلاعات است. دوباره تعریف نه چندان ناآشنای  $h_{MAP}$  را به خاطر بیاورید.

$$h_{MAP} = \arg \max_{h \in H} P(D|h)P(h)$$

این رابطه را می‌توان به صورت معادل با  $\log_2$  آن نیز نشان داد،

$$h_{MAP} = \arg \min_{h \in H} -\log_2 P(D|h) - \log_2 P(h) \quad (6.16)$$

جالب است که رابطه‌ی ۶.۱۶ را می‌توان طوری تفسیر کرد که فرضیه‌های کوتاه‌تر ارجح‌ترند، با فرض اینکه یک طرح نمایش خاص برای کد کردن فرضیه‌ها و داده‌ها استفاده کنیم. برای توضیح این، بیایید ابتدا یک نتیجه‌ی اساسی تئوری اطلاعات را معرفی کنیم: مسئله‌ی طراحی کدی برای ارسال پیام‌های تصادفی، را که در آن احتمال ارسال پیام  $i$  مقدار  $p_i$  است را در نظر بگیرید. در اینجا علاقه‌ی ما به فشردن‌ترین کد ممکن است؛ به عبارت دیگر علاقه‌ی ما به کدی است که امید تعداد بیت‌هایی که باید ارسال شوند تا یک پیام تصادفی فرستاده شود مینیمم کند. واضح است که برای مینیمم کردن امید طول کد ارسالی باید کدهای کوتاه‌تر را به پیام‌هایی اختصاص دهیم که احتمال بیشتری دارند. (Shannon and Weaver 1949) نشان دادند که کد بهینه (کدی که امید تعداد بیت‌های ارسالی را مینیمم می‌کند) به پیام  $i$ ،  $\log_2 p_i$  بیت برای کد کردن اختصاص می‌دهد. به این تعداد بیت که برای کد کردن پیام  $i$  توسط کد  $C$  لازم است طول توضیح پیام  $i$  بر اساس  $C$  نیز می‌گویند و با  $L_C(i)$  آنرا نشان می‌دهند.

<sup>1</sup> Minimum description length

بیابید حالا رابطه‌ی ۶.۱۶ را با توجه به نتیجه‌ی بالا از تئوری کد سازی بررسی کنیم.

- $-\log_2 P(h)$  اندازه‌ی توضیح  $h$  بر اساس کد بهینه‌ی تمامی فضای فرضیه‌ی  $H$  است. به عبارت دیگر، این مقدار اندازه‌ی توضیحات فرضیه‌ی  $h$  با استفاده از نمایش بهینه است. در نماد گذاری فعلی  $L_{C_H}(h) = -\log_2 P(h)$ ، که در آن  $C_H$  کد بهینه برای کد کردن فضای فرضیه‌ی  $H$  است.
- $-\log_2 P(D|h)$  اندازه‌ی توضیح داده‌های آموزشی  $D$  با معلوم بودن  $h$  توسط کد بهینه است. در نماد گذاری فعلی  $L_{C_{D|h}}(D|h) = -\log_2 P(D|h)$ ، که در آن  $C_{D|h}$  کد بهینه برای توضیح داده‌های  $D$  با فرض اینکه فرستنده و گیرنده هر دو مطلع از  $h$  هستند است.
- بنابراین می‌توانیم رابطه‌ی ۶.۱۶ را برای تعریف  $h_{MAP}$  بازنویسی کنیم و بگوییم  $h_{MAP}$  فرضیه‌ی  $h$  است که مجموع طول توضیحات فرضیه‌ها به علاوه‌ی طول توضیحات داده‌ها با معلوم بودن فرضیه را مینیمم می‌کند.

$$h_{MAP} = \arg \min_h L_{C_H}(h) + L_{C_{D|h}}(D|h)$$

در این رابطه  $C_H$  و  $C_{D|h}$  به ترتیب کدهای بهینه برای  $H$  و  $D$  با معلوم بودن  $h$  هستند.

قانون کمترین طول توضیح (MDL) توصیه می‌کند که فرضیه‌هایی را انتخاب کنیم که مجموع این دو طول توضیح را حداقل کنند. البته برای بکار بردن این قانون در عمل باید کد سازی یا نمایش خاصی را که با عمل یادگیری متناسب است انتخاب کنیم. با فرض اینکه ما از کدهای  $C_1$  و  $C_2$  برای نمایش فرضیه‌ها و داده‌ها با معلوم بودن فرضیه استفاده می‌کنیم، می‌توان MDL را به صورت زیر بیان کرد،

**قانون کمترین طول توضیح:** فرضیه‌ی  $h_{MDL}$  را انتخاب کن،

$$h_{MDL} = \arg \min_{h \in H} L_{C_1}(h) + L_{C_2}(D|h) \quad (6.17)$$

بررسی بالا نشان می‌دهد که اگر ما  $C_1$  را برای کد سازی بهینه‌ی فرضیه‌ها،  $C_H$  و  $C_2$  را برای کد سازی بهینه‌ی داده‌ها،  $C_{D|h}$ ، انتخاب کنیم داریم  $h_{MDL} = H_{MAP}$ .

به صورت مفهومی، می‌توان به قانون MDL به فرم ترجیح متدهای کوتاه‌تر برای کد سازی دوباره‌ی داده‌های آموزشی نگاه کرد که در آن هر دو معیار اندازه‌ی فرضیه و هزینه‌ی اضافی کد سازی داده‌ها به شرط معلوم بودن فرضیه در نظر گرفته می‌شود.

بیابید مثالی را در نظر بگیریم. فرض کنید قصد داریم از قانون MDL برای مسئله‌ی یادگیری درخت‌های تصمیم از داده‌های آموزشی‌ای استفاده کنیم. برای نمایش فرضیه  $C_1$  و داده‌های  $C_2$  چه نمایشی را باید در نظر بگیریم؟ برای  $C_1$  می‌توان به طور طبیعی یکی از کد سازی‌های واضح درخت تصمیم، که در آن طول توضیح با افزایش تعداد گره‌های درخت و تعداد یال‌ها افزایش می‌یابد را انتخاب کرد. اما چگونه باید با معلوم بودن یک درخت فرضیه‌ی خاص مجموعه‌ی داده‌های  $C_1$  را کد کرد. برای ساده نگه داشتن موضوع، فرض کنید که سری نمونه‌های  $\langle x_1 \dots x_n \rangle$  برای فرستنده و گیرنده معلوم باشد، پس تنها چیز باقیمانده برای ارسال دسته بندی‌های  $\langle f(x_1) \dots f(x_n) \rangle$  است. (توجه دارید که هزینه‌ی ارسال خود نمونه‌ها از درستی فرضیه مستقل است، پس به هر حال تأثیری بر انتخاب  $h_{MDL}$  ندارد). حال اگر دسته بندی‌های  $\langle f(x_1) \dots f(x_n) \rangle$  همان پیش بینی‌های فرضیه باشد، دیگر نیازی به ارسال اطلاعات در مورد نمونه‌ها نیست (گیرنده می‌تواند این مقادیر را با فرضیه‌ی ای که دریافت کرده محاسبه کند). پس بنابراین طول توضیحات لازم

با داشتن فرضیه در این حالت صفر است. در چنین شرایطی اگر نمونه‌هایی توسط  $h$  اشتباه دسته بندی شده باشند، لازم است پیغامی مبنی بر دسته بندی اشتباه این نمونه‌ها (طول این پیغام حداکثر  $\log_2 n$  بیت خواهد بود) را به همراه دسته بندی درست آن‌ها ارسال کنیم (این کار را می‌توان با پیغامی با حداکثر طول  $\log_2 k$  انجام داد که در آن  $k$  تعداد دسته بندی‌های ممکن هر نمونه است). در چنین شرایطی فرضیه‌ی  $h_{MDL}$  تحت کد سازی  $C_1$  و  $C_2$  فرضیه ای است که کمترین مجموع طول توضیح را لازم داشته باشد.

بنابراین قانون MDL راهی برای ارزیابی پیچیدگی فرضیه‌ها با تعداد اشتباه‌های فرضیه ارائه می‌کند. ممکن است این معیار فرضیه ای کوتاه‌تر را که اشتباهات کمی دارد را نسبت به یک فرضیه بلند تر که اشتباهی ندارد ترجیح دهد. MDL از این نظر، متدی مناسب برای برخورد با مسئله‌ی overfit است.

(Quinlar and Rivest 1989) آزمایشاتی را با استفاده از قانون MDL برای تشخیص بهترین اندازه‌ی درخت تصمیم انجام داده‌اند. آن‌ها گزارش داده‌اند که متد مبتنی بر MDL درخت‌هایی را ایجاد می‌کند که دقتی قابل مقایسه با درخت‌های خروجی الگوریتم‌های فصل ۳ دارند. (Mehta et al. 1995) نیز روش دیگری مبتنی بر MDL برای هرس درخت تصمیم ارائه می‌کند و آزمایش‌هایی را تشریح کرده که در آن روش مبتنی بر MDL نتایج قابل مقایسه ای با روش‌های معمول را می‌دهد.

چه نتیجه گیری‌ای را باید از بررسی قانون کمترین طول توضیح بگیریم؟ آیا این اثباتی بر این که تمامی فرضیه های کوتاه‌تر ارجحند است؟ خیر. بلکه ما اثبات کردیم که اگر نمایش فرضیه طوری انتخاب شود که کد سازی فرضیه‌ی  $h$ ،  $-\log_2 P(h)$  باشد و اگر کد سازی استثنا به گونه ای باشد که طول کد  $D$  با شرط معلوم بود  $h$ ،  $-\log_2 P(h|D)$ ، آنگاه قانون MDL فرضیه ای MAP خروجی خواهد داد. با این وجود، برای نشان دادن برقراری چنین شرطی باید تمامی احتمالات اولیه‌ی  $P(h)$  و  $P(D|h)$  را داشته باشیم. هیچ دلیلی برای این وجود ندارد که باور داشته باشیم که MDL برای هر کد سازی دلخواه  $C_1$  و  $C_2$  بر قرار است. ممکن گاهی برای طراح انسانی مشخص کردن نمایشی خاص برای دانش در مورد احتمالات نسبی فرضیه‌ها راحت‌تر از نمایش کامل احتمال دقیق هر یک از فرضیه‌ها باشد. توصیفات به کار رفته در ادبیات کاربرد MDL در مسائل یادگیری کاربردی گاهی شامل معیارهایی می‌شود که فرم خاصی از کد سازی  $C_1$  و  $C_2$  را توجیه می‌کند.

## ۶.۷ دسته بندی کننده‌ی بهینه‌ی بیز<sup>۱</sup>

تا اینجا به سؤال "محتمل‌ترین فرضیه با داشتن داده های آموزشی کدام است؟" پرداختیم، در واقع، این سؤال بیشتر شبیه این سؤال است که "محتمل‌ترین دسته بندی کننده نمونه های جدید با داشتن داده های آموزشی کدام است؟". با وجود اینکه ممکن است به نظر برسد که این سؤال دوم را می‌توان با اعمال فرضیه‌ی MAP به نمونه های جدید جواب داد، کاری بهتر ممکن است.

برای ایجاد شهود فضای فرضیه ای را در نظر بگیرید که سه فرضیه‌ی  $h_1$ ،  $h_2$  و  $h_3$  را شامل می‌شود. فرض کنید که احتمال ثانویه‌ی این فرضیه با داده های آموزشی به ترتیب ۴ و ۳ و ۳ است. بنابراین،  $h_1$  فرضیه‌ی MAP است. حال فرض کنید که نمونه‌ی جدید  $X$  به ما داده می‌شود که توسط  $h_1$  مثبت و توسط دو فرضیه‌ی  $h_2$  و  $h_3$  منفی دسته بندی می‌شود. با در نظر گرفتن تمامی فرضیه‌ها نمونه‌ی  $X$  به احتمال ۴ مثبت است (احتمال مربوط به فرضیه‌ی  $h_1$ )، و به احتمال ۶ منفی است. محتمل‌ترین دسته بندی (منفی) در این مثال با دسته بندی MAP متفاوت است.

<sup>1</sup> bayes optimal classifier

در کل محتمل ترین دسته بندی نمونه‌ی جدید از ترکیب پیش بینی‌های همه‌ی فرضیه‌ها بدست می‌آید، فقط هر فرضیه به اندازه‌ی احتمال ثانویه‌اش در این دسته بندی تأثیر گذار است. اگر دسته بندی ممکن نمونه‌ی جدید  $v_j$  عضو مجموعه‌ی  $V$  باشد،  $P(v_j|D)$  احتمال اینکه دسته بندی  $v_j$  برای نمونه‌ی جدید درست باشد به صورت زیر است،

$$P(v_j|D) = \sum_{h_i \in H} P(v_j|h_i)P(h_i|D)$$

دسته بندی ی بهینه‌ی نمونه‌ی جدید مقدار  $v_j$  است که با آن  $P(v_j|D)$  ماکزیمم می شود،

**دسته بندی ی بهینه‌ی بیز:**

$$\arg \max_{v_j \in V} \sum_{h_i \in H} P(v_j|h_i)P(h_i|D) \quad (6.18)$$

برای شهود در مثال بالا، مجموعه‌ی دسته بندی‌های نمونه‌ی جدید  $V = \{\oplus, \ominus\}$  است و

$$P(h_1|D) = .4, P(\ominus |h_1) = 0, P(\oplus |h_1) = 1$$

$$P(h_2|D) = .3, P(\ominus |h_2) = 1, P(\oplus |h_2) = 0$$

$$P(h_3|D) = .3, P(\ominus |h_3) = 1, P(\oplus |h_3) = 0$$

بنابراین،

$$\sum_{h_i \in H} P(\oplus |h_i)P(h_i|D) = .4$$

$$\sum_{h_i \in H} P(\ominus |h_i)P(h_i|D) = .6$$

9

$$\arg \max_{v_j \in \{\oplus, \ominus\}} \sum_{h_i \in H} P(v_j|h_i)P(h_i|D) = \ominus$$

هر سیستمی که نمونه‌های جدید را با رابطه‌ی ۶.۱۸ دسته بندی کند دسته بندی کننده‌ی بهینه‌ی بیز<sup>۱</sup> یا یادگیر بهینه‌ی بیز<sup>۲</sup> نامیده می‌شود. هیچ متد دسته بندی دیگری با همان فضای فرضیه ای و همان دانش اولیه نمی‌تواند به طور متوسط بازده بهتری داشته باشد. این متد احتمال اینکه نمونه‌ی جدید درست دسته بندی شود را با معلوم بودن داده‌های موجود و فضای فرضیه ای احتمالات اولیه‌ی فرضیه‌ها حداکثر می‌کند.

<sup>1</sup> Bayes optimal classifier

<sup>2</sup> Bayes optimal learner

برای مثال در یادگیری مفاهیم حقیقی مقدار با استفاده از فضای ویژه، همان طور که در قسمت قبلی هم گفته شد، دسته بندی بهینه‌ی بیز نمونه های جدید با دادن وزن (احتمال ثانویه‌ی فرضیه) و رای گیری بین اعضای فضای ویژه انجام می‌گرفت.

یکی از ویژگی‌های عجیب دسته بندی کننده‌ی بهینه‌ی بیز این است که پیش بینی‌هایی که انجام می‌دهد ممکن است فرضیه ای را تشکیل دهد که حتی در  $H$  موجود نیست. تصور کنید که از رابطه‌ی ۶.۱۸ برای دسته بندی تمامی نمونه های  $X$  استفاده کرده‌ایم. این دسته بندی نمونه‌ها که بدین صورت تعریف می‌شود الزاماً با فرضیه ای مثل  $h$  در  $H$  سازگار نیست. یکی از روش‌های نگاه به این وضعیت تصور دسته بندی کننده بهینه‌ی بیز به عنوان عاملی است که فضای فرضیه ای  $H'$  را به طرز موثری، که با فضای فرضیه ای  $H$  (که قضیه بیز روی آن اعمال شده) فرق دارد، در نظر می‌گیرد. در کل،  $H'$  به صورت موثر فرضیه‌هایی که مقایسه ای خطی بین ترکیبات پیش بینی‌های فرضیه های مختلف  $H$  می‌کنند را شامل می‌شود.

## ۶.۸ الگوریتم گیبس

با وجود اینکه دسته بندی کننده‌ی بهینه‌ی بیز بهترین عملکرد ممکن را با داشتن داده های آموزشی دارد، اما اعمال آن هزینه بر است. این هزینه در محاسبه‌ی احتمال ثانویه‌ی تمامی فرضیه های  $H$  و ترکیب پیش بینی‌هایشان برای هر نمونه‌ی جدید است.

یک روش جایگزین، ولی کمتر بهینه الگوریتم گیبس (رجوع کنید به (Oppen and Haussler 1991) است، که به صورت زیر تعریف می‌شود:

۱. فرضیه ای مثل  $h$  از  $H$  به طور تصادفی و با توزیع احتمالات ثانویه انتخاب کن.
  ۲. از  $h$  برای دسته بندی نمونه‌ی جدید بعدی استفاده کن.
- زمانی که نمونه‌ی جدیدی برای دسته بندی ارائه می‌شود، الگوریتم گیبس به سادگی فرضیه ای به طور تصادفی و با توزیع احتمالات ثانویه انتخاب می‌کند و دسته بندی آن را به عنوان خروجی می‌دهد. جالب‌تر اینکه، می‌توان نشان داد که در شرایطی امید تعداد دسته بندی‌های غلط این الگوریتم حداکثر دو برابر امید خطای دسته بندی کننده‌ی بهینه‌ی بیز است (Haussler 1994). به عبارت دقیق‌تر، مقدار امید برای تمامی مفاهیم هدف تصادفی و توزیع احتمال اولیه‌ی یادگیر محاسبه شده. در چنین شرایطی، مقدار امید خطای الگوریتم گیبس دو برابر بدتر از مقدار امید خطای دسته بندی کننده‌ی بهینه‌ی بیز است.

این نتیجه معنای جالبی در مسائل یادگیری مفهوم که قبلاً در موردشان بحث کردیم دارد. در کل، این نتیجه نشان می‌دهد که اگر یادگیر احتمالات اولیه  $H$  را یکسان فرض کند، و مفاهیم هدف نیز در واقع با چنین احتمالی انتخاب شوند، آنگاه دسته بندی نمونه‌ی بعدی با فرضیه ای که به طور تصادفی از فضای ویژه انتخاب می‌شود (با توزیعی یکنواخت)، حداکثر دو برابر امید خطای دسته بندی کننده‌ی بهینه‌ی بیز، امید خطا خواهد داشت. دوباره، با نمونه ای از بررسی بیزی یک الگوریتم غیر بیزی طرف هستیم که این بررسی میزان کارایی آن الگوریتم را مشخص می‌کند.

## ۶.۹ دسته بندی کننده ی بیز

یکی از متدهای پر کاربرد یادگیری بیزی، یادگیر ساده ی بیز<sup>۱</sup> است که معمولاً دسته بندی کننده ی ساده ی بیز<sup>۲</sup> نیز نامیده می شود. در بعضی کاربردها کارایی این متد قابل مقایسه با شبکه های عصبی و یادگیری درختی است. در این بخش دسته بندی کننده ی ساده ی بیز را مورد بحث و بررسی قرار می دهیم و در بخش بعدی آن را در مسئله یادگیری ای واقعی دسته بندی متون زبان های طبیعی به کار می بریم.

دسته بندی کننده ی ساده ی بیز در کار های یادگیری ای به کار می رود که در آن  $X$  با عطفی از مقادیر ویژگی ها مشخص می شود و تابع هدف  $f(x)$  می تواند هر مقدار از مجموعه ی  $V$  باشد. مجموعه ای از نمونه های آموزشی تابع هدف و نمونه ای جدید که با ویژگی هایش توصیف شده به یادگیر داده می شود،  $\langle a_1, a_2 \dots a_n \rangle$  و از آن خواسته می شود که مقدار تابع هدف یا دسته بندی تابع هدف را برای این نمونه ی جدید پیش بینی کند.

روش بیزی برای دسته بندی نمونه ی جدید، دسته بندی آن بر اساس محتمل ترین مقدار تابع هدف،  $v_{MAP}$  است با داشتن نمونه های  $\langle a_1, a_2 \dots a_n \rangle$  است.

$$v_{MAP} = \arg \max_{v_j \in V} P(v_j | a_1, a_2 \dots a_n)$$

با استفاده از قضیه ی بیز این رابطه را بازنویسی می کنیم،

$$\begin{aligned} v_{MAP} &= \arg \max_{v_j \in V} \frac{P(a_1, a_2 \dots a_n | v_j) P(v_j)}{P(a_1, a_2 \dots a_n)} \\ &= \arg \max_{v_j \in V} P(a_1, a_2 \dots a_n | v_j) P(v_j) \end{aligned} \quad (6.19)$$

حال می توانیم دو عبارت رابطه ی ۶.۱۹ را بر اساس داده های آموزشی تخمین بزنیم. تخمین مقادیر  $P(v_j)$  با شمارش تعداد تکرار مقدار های ویژگی هدف در بین داده های آموزشی بسیار ساده است. با این وجود، تخمین عبارتی با فرم  $P(a_1, a_2 \dots a_n | v_j)$  بدین صورت ممکن نیست، مگر اینکه مجموعه ی داده های آموزشی مان بسیار بزرگ باشد. مشکل اینجاست که تعداد این چنین عبارت هایی مساوی تعداد نمونه های ممکن ضربدر تعداد مقادیر ممکن تابع هدف است. بنابراین لازم است که هر نمونه ممکن در فضای نمونه ای چندین بار مشاهده شود تا تخمین احتمال قابل اطمینان باشد.

دسته بندی کننده ی ساده ی بیز بر اساس یک فرض ساده سازی است، مقدار ویژگی ها با معلوم بودن مقدار هدف مستقلند. به عبارت دیگر، فرض هایی که با داشتن مقدار هدف نمونه می توان زد، احتمال مشاهده ی عطف  $a_1, a_2 \dots a_n$  فقط وابسته به احتمال تک تک این نمونه هاست:  $P(a_1, a_2 \dots a_n | v_j) = \prod_i P(a_i | v_j)$ . با جایگذاری این رابطه در رابطه ی ۶.۱۹ به دسته بندی کننده ی ساده ی بیز می رسیم.

### دسته بندی کننده ی ساده بیز:

<sup>1</sup> Naïve bayes learner

<sup>2</sup> Naïve bayes classifier



$$v_{NB} = \arg \max_{v_j \in V} P(v_j) \prod_i P(a_i | v_j) \quad (6.20)$$

در این رابطه  $v_{NB}$  نماد مقدار هدفی خروجی دسته بندی کننده‌ی ساده‌ی بیز است. توجه دارید که در یک دسته بندی کننده‌ی ساده‌ی بیز تعداد جملات متمایز  $P(a_i | v_j)$  موجود، که باید بر اساس داده‌های آموزشی تخمین زده شود، ضرب تعداد مقادیر ویژگی‌ها و تعداد مقادیر هدف است، این عدد در نگاه اول، نسبت به تعداد جملات ممکن  $P(a_1, a_2 \dots a_b | v_j)$  بسیار کوچکتر است.

به طور خلاصه، متد یادگیری ساده‌ی بیز مرحله‌ای دارد که در آن جملات مختلف  $P(a_i | v_j)$  و  $P(v_j)$  بر اساس تعداد تکرارشان در میان نمونه‌های آموزشی تخمین زده می‌شوند. مجموعه‌ی این تخمین‌ها تعیین کننده‌ی فرضیه‌ی تخمینی خواهد بود. این فرضیه، برای دسته بندی نمونه‌های جدید رابطه‌ی ۶.۲۰ را بکار خواهد بست. هرگاه که فرض استقلال شرطی ارضا می‌شود، و دسته بندی ساده‌ی بیز  $v_{NB}$  همان دسته بندی MAP خواهد بود.

یکی از تفاوت‌های جالب دسته بندی کننده‌ی ساده‌ی بیز و دیگر متد‌های یادگیری بحث شده، این است که این روش جستجویی صریح در میان فرضیه‌های ممکن انجام نمی‌دهد (در چنین شرایطی، فضای فرضیه‌ها همان فضای مقادیر ممکن قابل نسبت به متغیر  $P(v_j)$  و  $P(a_i | v_j)$  است). در مقابل، فرضیه‌ها بدون جستجو و فقط با شمارش تعداد تکرار ترکیب‌های مختلف داده در میان نمونه‌های آموزشی ایجاد می‌شوند.

#### ۶.۹.۱ مثالی توضیحی

بیابید دسته بندی کننده‌ی ساده‌ی بیز را به مسئله یادگیری مفهومی که در فصل یادگیری درختی مطرح شد بکار ببریم: دسته بندی روزها بر اساس اینکه کسی تنیس بازی خواهد کرد یا خیر. جدول ۳.۲ مجموعه‌ای از ۱۴ نمونه‌ی آموزشی را برای مفهوم PlayTennis نشان می‌دهد، در اینجا روزها با ویژگی‌های Outlook, Temperature, Humidity, و Wind توصیف می‌شوند. در اینجا از دسته بندی کننده‌ی ساده‌ی بیز و داده‌های آموزشی این جدول برای دسته بندی نمونه‌ی جدید زیر استفاده می‌کنیم:

<Outlook=sunny, Temperature=cool, Humidity=high, Wind=strong>

هدف در اینجا پیش بینی مقدار هدف (Yes یا No) مفهوم هدف PlayTennis برای نمونه‌ی جدید است. با مقدار گذاری رابطه‌ی ۶.۲۰ برای این کار مقدار  $v_{NB}$  به صورت زیر محاسبه می‌شود.

$$\begin{aligned} v_{NB} &= \arg \max_{v_j \in \{yes, no\}} P(v_j) \prod_i P(a_i | v_j) \\ &= \arg \max_{v_j \in \{yes, no\}} P(v_j) P(\text{Outlook} = \text{sunny} | v_j) P(\text{Temperature} = \text{cool} | v_j) \\ &\quad P(\text{Humidity} = \text{High} | v_j) P(\text{Wind} = \text{strong} | v_j) \end{aligned} \quad (6.21)$$

توجه دارید که در عبارت آخری  $a_i$  با استفاده از مقادیر ویژگی‌های نمونه‌ی جدید نوشته شده است. برای محاسبه‌ی  $v_{NB}$  به ۱۰ احتمال نیاز داریم که از روی داده‌های آموزشی تخمین زده می‌شوند. ابتدا، احتمال مقادیر مختلف هدف، که می‌توان آن‌را به سادگی با شمارش تکرار مقادیر از نمونه‌های آموزشی استخراج کرد.

$$P(\text{PlayTennis} = \text{yes}) = \frac{9}{14} = .64$$

$$P(\text{PlayTennis} = \text{no}) = \frac{5}{14} = .36$$

به طور مشابه می‌توان احتمالات شرطی را تخمین زد. برای مثال، برای  $\text{Wind} = \text{strong}$  داریم،

$$P(\text{Wind} = \text{strong} | \text{PlayTennis} = \text{yes}) = \frac{3}{9} = .33$$

$$P(\text{Wind} = \text{strong} | \text{PlayTennis} = \text{no}) = \frac{3}{5} = .60$$

با استفاده از تخمین‌های احتمالات مذکور و تخمین مشابه دیگر ویژگی‌ها،  $v_{NB}$  را بر اساس رابطه‌ی ۶.۲۱ به صورت زیر محاسبه می‌کنیم،

$$P(\text{yes}) P(\text{sunny}|\text{yes}) P(\text{cool}|\text{yes}) P(\text{high}|\text{yes}) P(\text{strong}|\text{yes}) = .0053$$

$$P(\text{no}) P(\text{sunny}|\text{no}) P(\text{cool}|\text{no}) P(\text{high}|\text{no}) P(\text{strong}|\text{no}) = .0053$$

دسته بندی کننده‌ی ساده‌ی بیز احتمالات تخمینی بر اساس داده‌های آموزشی موجود مقدار  $\text{PlayTennis} = \text{no}$  را به این نمونه‌ی جدید اختصاص می‌دهد. علاوه بر این، با نرمالیزه کردن کمیت‌های بالا (طوری که جمعشان یک شود) می‌توان احتمال شرطی اینکه مقدار تابع هدف  $\text{no}$  باشد را حساب کرد. برای مثال فعلی، این احتمال مقدار  $.795 = \frac{.0206}{.0206 + .0053}$  است.

#### ۶.۹.۱.۱ تخمین احتمالات

تا به حال، احتمالات را با نسبت تعداد مشاهده‌ی اتفاق به کل حالات را تخمین زدیم. برای مثال، در مثال بالا مقدار  $P(\text{Wind}=\text{strong} | \text{PlayTennis}=\text{no})$  را با نسبت  $\frac{n_c}{n}$  تخمین زدیم، در این نسبت  $n=5$  تعداد نمونه‌های آموزشی  $\text{PlayTennis}=\text{no}$  و  $n_c = 3$  تعداد نمونه‌هایی بود که در آن  $\text{Wind}=\text{strong}$  بود.

با وجود اینکه در بسیاری از موارد این نسبت تخمین خوبی از احتمال به ما می‌دهد، اما زمانی که  $n_c$  بسیار کوچک است تخمین ضعیف خواهد بود. برای درک این مشکل، فرض کنید که در حقیقت مقدار احتمال  $P(\text{Wind}=\text{strong} | \text{PlayTennis}=\text{no})$  برابر با  $.08$  باشد و در مجموعه‌ی نمونه‌های ما فقط ۵ نمونه مقدار  $\text{PlayTennis}=\text{no}$  را داشته باشند. با این فرض‌ها،  $n_c$  به احتمال زیادی صفر خواهد بود. این حقیقت دو مشکل ایجاد می‌کند. ابتدا اینکه  $\frac{n_c}{n}$  تخمینی بایاس دار و دست کم گیرنده از مقدار احتمال خواهد بود. دوم اینکه زمانی که تخمین این احتمال صفر است باعث می‌شود که تمامی نمونه‌هایی که در آن‌ها  $\text{Wind}=\text{strong}$  است جزو دسته‌ی دیگر اطلاق شوند.

برای پرهیز از این مشکل می‌توان از روش بیزی برای تخمین احتمالات استفاده کرد، برای این کار تخمین  $m^1$  را به فرم زیر تعریف می‌کنیم.

تخمین  $m$  احتمالات:

<sup>1</sup> m-estimate

(6.22)

$$\frac{n_c + mp}{n + m}$$

در این رابطه  $n_c$  و  $n$  همان مقادیر رابطه‌ی قبلی‌اند و  $p$  احتمال اولیه‌ی مقدار تخمینی است.  $m$  ثابتی که اندازه‌ی نمونه‌ی معادل<sup>1</sup> نامیده می‌شود. این ثابت مشخص می‌کند که مقدار احتمال به چه میزان به نمونه‌های آموزشی وابسته باشد. یکی از روش‌های متداول انتخاب  $p$  بدون داشتن هیچ اطلاعات قبلی‌ای، یکنواخت گرفتن تمامی احتمالات اولیه است؛ بدین معنا که اگر ویژگی‌ای  $k$  مقدار ممکن دارد خواهیم داشت که  $p = \frac{1}{k}$ . برای مثال، در تخمین  $P(\text{Wind}=\text{strong}|\text{PlayTennis}=\text{no})$  می‌دانیم که ویژگی Wind دو مقدار ممکن دارد، پس با احتمال اولیه‌ی یکنواخت خواهیم داشت که  $p=0.5$ . توجه دارید که اگر  $m$  را صفر انتخاب کنیم، تخمین  $m$  معادل همان کسر ساده‌ی  $\frac{n_c}{n}$  می‌شود. اگر مقادیر  $m$  و  $n$  هر دو غیر صفر باشند، حاصل تخمین  $m$  میانگین دو مقدار با وزن  $m$  خواهد بود.  $m$  ثابت اندازه‌ی نمونه‌ی معادل نامیده می‌شود از این رو که رابطه‌ی ۶.۲۲ را می‌توان به صورت ترکیب  $n$  مشاهده‌ی واقعی و  $m$  مشاهده‌ی مجازی (با احتمال  $p$ ) در نظر گرفت.

## ۶.۱۰ یک مثال: یادگیری دسته بندی متون

برای تصور اهمیت کاربردی متدهای یادگیری بیز، مسئله‌ی یادگیری‌ای را در نظر بگیرید که در آن نمونه‌ها متنند. برای مثال، شاید بخواهیم مفهوم هدف "مقالات خبری الکترونیکی جالب برای من" یا "صفحاتی از Web که یادگیری ماشین در آن‌ها بحث شده" را یاد بگیریم. در هر دو حالت، اگر یک کامپیوتر بتواند چنین کاری را انجام دهد می‌تواند به جای تعداد بسیاری زیادی از متون وب فقط مربوط‌ترین نتیجه جستجو روی وب را به کاربر ارائه کند.

در اینجا الگوریتمی کلی بر اساس دسته بندی کننده‌ی ساده‌ی بیز برای یادگیری دسته بندی متون ارائه می‌کنیم. جالب است که روش‌های احتمالی مثل آنچه پیش‌تر توضیح دادیم یکی از مؤثرترین الگوریتم‌های شناخته شده برای دسته بندی متون هستند. مثال‌هایی از چنین سیستم‌هایی در (Lewis 1991)، (Lang 1995) و (Joachims 1996) توصیف شده‌اند.

الگوریتم دسته بندی کننده‌ی ساده بیز که توضیح خواهیم داد با تعریف مسئله‌ی کلی تطابق دارد. فضای نمونه‌ی  $X$  را که شامل تمامی مستندات متنی (تمامی رشته کلمات و علامات با طول دلخواه) است در نظر بگیرید. به ما نمونه‌های آموزشی تابع هدف مجهول  $f(x)$  داده شده است، این تابع مجهول ممکن است هر یک از اعضای  $V$  باشد. هدف ما یادگیری از این نمونه‌های آموزشی برای پیش بینی مقدار هدف متنی جدید است. برای تصور، تابع هدف دسته بندی متون به دو دسته‌ی جذاب و غیر جذاب برای فرد بخصوص است، برای این تابع هدف مقادیر like (جذاب) و dislike (غیر جذاب) برای دسته بندی این دو مجموعه تعریف می‌شود.

دو مشکل اصلی برای کاربرد دسته بندی کننده‌ی ساده‌ی بیز در مسائل دسته بندی متن وجود دارد. اول اینکه با چه روشی یک متن دلخواه را با مقدار ویژگی‌هایی نمایش داد و دوم اینکه احتمالات لازم برای دسته بندی کننده‌ی ساده‌ی بیز را با چه روشی تخمین زد.

روش ما در نمایش متن دلخواه به طرز مشکل سازی ساده است: با داشتن یک متن، مثل همین پاراگراف، باید یک ویژگی برای هر مکان کلمه در متن تعریف کنیم و مقدار ویژگی‌ها را هم کلمات آن مکان‌ها در نظر بگیریم. بنابراین این پاراگراف ۹۷ مقدار ویژگی خواهد داشت که متناسب

<sup>1</sup> equivalent sample size

با ۹۷ کلمه‌ی این پاراگراف است. مقدار ویژگی اول کلمه‌ی "روش" و مقدار ویژگی دوم کلمه‌ی "ما" خواهد بود و ... توجه دارید که با این روش متون بلند تعداد بیشتری ویژگی خواهند داشت. همان طور که بعداً نیز خواهیم دید، این تفاوت هیچ مشکلی ایجاد نمی‌کند.

با این نمایش برای متون، حال می‌توانیم دسته بندی کننده‌ی ساده‌ی بیز را به مسئله اعمال کنیم. بیا بید به خاطر حفظ سادگی، فرض کنیم که ۷۰۰ متن آموزشی که فردی dislike دسته بندی کرده به همراه ۳۰۰ متن دیگر که like دسته بندی شده در اختیار است. حال متن جدیدی در اختیار یادگیر قرار گرفته و از وی دسته بندی این متن سؤال می‌شود. دوباره به خاطر سادگی، بیا بید فرض کنیم که متن جدید پاراگراف قبلی باشد. در چنین شرایطی، اگر رابطه‌ی ۶.۲۰ را برای دسته بندی مقدار دهی کنیم خواهیم داشت که،

$$v_{NB} = \arg \max_{v_j \in \{like, dislike\}} P(v_j) \prod_{i=1}^{97} P(a_i | v_j)$$

$$\arg \max_{v_j \in \{like, dislike\}} P(v_j) P(a_1 = \text{"روش"} | v_j) P(a_2 = \text{"ما"} | v_j)$$

$$\dots P(a_{97} = \text{"نمی‌کند"} | v_j)$$

به طور خلاصه، دسته بندی ساده‌ی بیز  $v_{NB}$  دسته بندی‌ای است که احتمال مشاهده‌ی کلماتی را که واقعاً در متن بوده‌اند را با توجه به فرض مستقل بودن ساده‌ی بیز ماکزیم می‌کند. فرض مستقل بودن  $P(a_1, \dots, a_{97} | v_j) = \prod_{i=1}^{97} P(a_i | v_j)$  در این تعریف مسئله فرض می‌کند که احتمال هر کلمه با داشتن دسته بندی متن  $v_j$ ، برای هر مکان در متن مستقل از دیگر کلمات دیگر مکان‌هاست. توجه می‌کنید که این فرض به وضوح غلط است. برای مثال، در متون ممکن است احتمال آمدن کلمه‌ی "ماشین" بعد از کلمه‌ی "یادگیری" بسیار بیشتر از دیگر کلمات باشد. با وجود این نقص مشهود فرض مستقل بودن، انتخاب دیگری جز این نداریم، زیرا که بدون این شرط تعداد جملات احتمالی‌ای که باید محاسبه شوند به شدت زیاد می‌شوند. خوشبختانه در یادگیر ساده‌ی بیز در بسیاری از موارد در مسائل دسته بندی متون بر خلاف غلط بودن فرض استقلال نتایج خوبی بدست می‌آید. (Domingos and Pazzani 1996) بررسی جالبی از این پدیده‌ی تصادفی ارائه می‌کند.

برای محاسبه‌ی  $v_{NB}$  با استفاده از رابطه‌ی بالا، نیاز داریم که احتمال جمله‌های  $P(v_j)$  و  $P(a_i = w_k | v_j)$  را محاسبه کنیم (در این مسئله  $w_k$ ،  $k$ امین واژه‌ی واژگان زبان فارسی است). احتمالات جمله‌ی اول را می‌توان به سادگی و با یک نسبت ساده از نمونه‌های آموزشی محاسبه کرد، (در مثال فعلی  $P(like)=0.3$  و  $P(dislike)=0.7$ ). مثل همیشه تخمین دسته بندی احتمالات شرطی (مثل  $P(a_1 = \text{"روش"} | dislike)$ ) مشکل ساز تر خواهد بود زیرا که باید چنین جمله‌ی احتمالی را برای هر ترکیب از متن ممکن کلمات فارسی و تابع هدف محاسبه کنیم. متأسفانه با 50,000 کلمه در واژگان زبان و ۲ حالت مقادیر هدف و ۹۷ کلمه‌ی نمونه‌ی فعلی به تقریباً محاسبه‌ی  $10,000,000 \approx 2.97 \times 50,000$  حالت نیاز خواهیم داشت.

خوشبختانه، می‌توانیم فرض استدلالی دیگری نیز که تعداد احتمالات را کم بکند به فرض‌ها پیشین اضافه کنیم. در کل، می‌توانیم احتمال بر خورد با کلمه‌ی خاص  $w_k$  (مثل "شکلات") را مستقل از مکان حضورش (مثل  $a_{23}$  یا  $a_{95}$ ) در نظر بگیریم. به عبارت رسمی‌تر، ویژگی‌ها از هم مستقلند و توزیع یکسان نیز دارند، با معلوم بودن دسته بندی هدف؛ برای تمامی  $m, k, j, i$  داریم  $P(a_i = w_k | v_j) = P(a_m = w_k | v_j)$  بنابراین تخمین می‌زنیم که کل مجموعه احتمالات  $P(a_1 = w_k | v_j)$ ،  $P(a_2 = w_k | v_j)$  ... برابر با یک مقدار مستقل مثبت  $P(w_k | v_j)$  باشد، یعنی این مقدار احتمال به مکان کلمه بستگی ندارد. تأثیر این فرض این است که حال فقط نیاز به محاسبه‌ی

250,000 جمله‌ی مستقل به فرم  $P(w_k|v_j)$  داریم. این مقدار هنوز زیاد است اما دیگر در حد کنترل است. توجه دارید که در شرایطی که داده‌های آموزشی محدود باشند، مزیت اولیه‌ی این فرض افزایش تعداد نمونه‌های موجود برای تخمین هر یک از احتمالات و متعاقباً دقت دسته‌بندی است.

برای کامل کردن طراحی الگوریتم یادگیریمان، هنوز باید متدی برای تخمین جملات احتمالات پیدا کنیم. از تخمین  $m$ ، که در رابطه‌ی ۶.۲۲ آمد، و احتمالات اولیه‌ی یکنواخت و اندازه‌ی واژگان موجود برای  $P(w_k, v_j)$  داریم،

$$\frac{n_k + 1}{n + |\text{Vocabulary}|}$$

در این رابطه  $n$  کل تعداد کلمات ممکن در نمونه‌های آموزشی است با مقدار تابع هدف  $v_j$  است،  $n_k$  تعداد تکرار کلمه‌ی  $w_k$  در میان  $n$  کلمه‌ی ممکن است و  $|\text{Vocabulary}|$  نیز تعداد خالص کل کلمات (و دیگر نشانه‌های) موجود در نمونه‌های آموزشی است.

به طور خلاصه اینکه الگوریتم نهایی از دسته‌بندی کننده‌ی ساده‌ی بیز به همراه فرض استقلال کلمات از مکانشان استفاده می‌کند. الگوریتم نهایی در جدول ۶.۲ آورده شده است. توجه می‌کنید که این الگوریتم به نسبت ساده است. در طول یادگیری، زیر روال Learn-Naive-bayes-text تمامی متون آموزشی را برای استخراج تمام کلمات و نشانه‌های موجود در متون بررسی می‌کند و تعداد تکرارشان را در دسته‌بندی‌های مختلف تابع می‌شمرد تا تخمین‌های لازم را بدست آورد. سپس، برای یک متن جدید (که لازم است دسته‌بندی شود) فرآیند Classify-naive-bayes-text با توجه به رابطه‌ی ۶.۲۰ از این تخمین احتمالات برای محاسبه‌ی  $v_{NB}$  استفاده می‌کند. توجه دارید که کلمه که در متن جدید ظاهر شده که در متون قبلی نبوده‌اند توسط Classify-naive-bayes-text نادیده گرفته می‌شود. کد و مجموعه‌ی داده‌های آموزشی در آدرس <http://www.cs.cmu.edu/~tom/book.html> موجود است.

### ۶.۱۰.۱ نتیجه‌های تجربی

الگوریتم جدول ۶.۲ به چه میزان کارایی دارد؟ در یک آزمایش (Joachims 1996)، الگوریتم بسیار مشابهی برای دسته‌بندی مقالات خبری یوزنت<sup>۱</sup> بکار رفت. دسته‌بندی مقاله در این مثال اسم گروه خبری مقاله در یوزنت بود. الگوریتمی که هر مقاله را پس از دسته‌بندی در جای اصلی خود قرار می‌دهد. در این آزمایش ۲۰ گروه خبری الکترونیکی در نظر گرفته شد (که در جدول ۶.۳ نیز آمده‌اند)، سپس 1,000 مقاله از هر گروه خبری جمع شد تا تعداد نمونه‌ها به 20,000 برسد. الگوریتم ساده‌ی بیز دو سوم از این 20,000 متن به عنوان نمونه‌های آموزشی آموزش داده شد و سپس کارایی الگوریتم برای یک سوم باقیمانده ارزیابی شد. از ۲۰ گروه خبری ممکن، حداکثر مقدار دسته‌بندی درست اتفاقی ۵٪ خواهد بود، اما دقت دسته‌بندی الگوریتم ۸۹٪ اندازه‌گیری شد. الگوریتم به کار رفته در این آزمایش فقط یک تفاوت کوچک با الگوریتم جدول ۶.۲ داشت، یک زیر مجموعه از کلمات متون به عنوان واژگان<sup>۲</sup> در نظر گرفته شده بود. به عبارت دقیق‌تر، ۱۰۰ کلمه‌ی پرکاربرد تر واژگان در آن در نظر گرفته نشده بود (کلماتی مثل "این")، و همچنین تمامی کلماتی که کمتر از ۳ بار ظاهر شده بودند نادیده گرفته شدند. واژگان بدست آمده بدین ترتیب تقریباً 38,500 کلمه داشت.

<sup>1</sup> use net

<sup>2</sup> Vocabulary

نتایج چشم گیر دیگری نیز توسط دیگر روش های یادگیری آماری متون بدست آمده است. برای مثال، (Lang 1995) نسخه ای دیگر از الگوریتم ساده ی بیز را توصیف کرده و آن را در یادگیری مفهوم هدف "مقالات یوزنتی که من به آن ها علاقه دارم" به کار می برد. وی سیستم NewsWeeder را معرفی می کند، برنامه ای که به کاربران اجازه می دهد تا متون را بعد از خواند ارزیابی<sup>۱</sup> کنند. سیستم NewsWeeder از این ارزیابی ها به عنوان نمونه های آموزشی برای پیش بینی اینکه مقاله ای برای کاربر جالب است یا خیر استفاده می کند، پس برنامه می تواند مقالاتی که پیش بینی می کند کاربر به خواندن آن ها علاقه دارد را به وی پیشنهاد کند. (Lang 1995) آزمایشی را گزارش می کند که در آن NewsWeeder از اطلاعات یاد گرفته خود بر اساس علاقه ی کاربر، مقاله ای که بالاترین مقدار پیش بینی ارزیابی را دارد به کاربر ارائه می دهد. با ذخیره ی ۱۰٪ اول این مقالات اتوماتیک ارزیابی شده، برنامه مجموعه ای از مقالات خواهد داشت که نسبت به مجموعه ی کل مقالات سه تا چهار برابر برای کاربر جالب ترند. برای مثال، برای یک کاربر نسبت مقالاتی که "جالب"<sup>۲</sup> دسته بندی می کند در کل ۱۶٪ است اما در میان این مقالات ۵۹٪ توصیه ی NewsWeeder بوده.

تعداد زیاد روش های غیر بیزی آماری برای یادگیری متون متداولند، بسیاری از این روش ها بر اساس معیارهای مشابه استخراج اطلاعات هستند. (Rocchio 1971; Salton). الگوریتم های یادگیری متون دیگر در (Hearst and Hirsh 1996) آورده شده است.

## ۶.۱۱ شبکه های باور بیزی

همان طور که در دو قسمت قبلی نیز گفته شد، دسته بندی کننده ی ساده ی بیز از فرض اینکه احتمالات شرطی  $a_1 \dots a_2$  با داشتن مقدار تابع هدف  $V$  مستقلاً استفاده ی شدیدی می کند. این فرض به طور قابل توجهی میزان پیچیدگی یادگیری تابع هدف را کاهش می دهد. با این فرض، دسته بندی کننده ی ساده ی بیز دسته بندی بهینه ی بیز را خروجی می دهد. با این وجود، در بسیاری از موارد این شرط مستقل بودن به شدت محدود کننده است.

شبکه های باور بیزی<sup>۳</sup> توزیع احتمالات حاکم بر مجموعه ی متغیرهایی که با دسته ای از فرض استقلال احتمالات شرطی مشخص می شوند را توصیف می کنند. بر خلاف دسته بندی کننده ی ساده ی بیز که فرض می کرد تمامی متغیرهای به طور شرطی با معلوم بودن فرضیه ی  $h$  مستقلاًند، شبکه های باور بیزی فرض های استقلال احتمالات را در زیر مجموعه های متغیرها درست می دانند. بنابراین، شبکه های باور بیزی، روشی میانی که شرطی آزادتر از فرض مستقل بودن تمامی متغیرهای دسته بندی کننده ی ساده ی بیز و محدود کننده تر از پرهیز از هر گونه شرط استقلال است، ارائه می کنند. شبکه های باور بیز یکی از موضوعات مورد توجه تحقیقات فعلی هستند، و دامنه ی وسیعی از الگوریتم ها برای یادگیری و استنتاج از آن ها ارائه شده است. در این بخش مفاهیم کلیدی و نحوه ی نمایش شبکه های باور بیزی را معرفی خواهیم کرد. اطلاعات دقیق تر در این زمینه (Pearl 1988) و (Russell and Norving 1995) و (Heckerman 1995) و (Jensen 1996) آمده است.

در کل، یک شبکه ی باور بیز توزیع های احتمال دسته ای از متغیرها را توصیف می کند. مجموعه ی دلخواهی از متغیرهای تصادفی  $Y_1 \dots Y_n$  را در نظر بگیرید که هر  $Y_i$  می تواند هر یک از مقادیر مجموعه ی  $V(Y_i)$  را داشته باشد. فضای توأم<sup>۴</sup> را مجموعه ی متغیرهای  $Y$  که از ضرب

<sup>1</sup> rate

<sup>2</sup> interesting

<sup>3</sup> bayesian belief networks

<sup>4</sup> joint space

خارجی  $V(Y_1) \times V(Y_2) \dots V(Y_n)$  بدست می‌آید تعریف می‌کنیم. به عبارت دیگر، هر عضو فضای توأم متناسب با یکی از مقادیر ممکن متغیرهای  $\langle Y_1 \dots Y_n \rangle$  است. توزیع احتمال این فضای توأم، توزیع احتمال توأم<sup>۱</sup> نامیده می‌شود. توزیع احتمال توأم، احتمال مشاهده‌ی هر یک از نمونه‌های  $\langle Y_1 \dots Y_n \rangle$  را مشخص می‌کند. یک شبکه‌ی باور بیز توزیع احتمال توأم یک مجموعه از متغیرها را توصیف می‌کند.

### ۶.۱۱.۱ شرط استقلال

بیا بید بحثمان درباره‌ی شبکه‌های باور بیزی را با تعریف دقیق مفهوم استقلال آغاز کنیم. فرض کنید  $X$ ،  $Y$  و  $Z$  سه متغیر تصادفی گسسته مقدار باشند، زمانی می‌گوییم که  $X$  از  $Y$  به شرط  $Z$  مستقل است که توزیع احتمال حاکم بر  $X$  با فرض داشتن مقدار  $Z$  مستقل از مقدار  $Y$  باشد؛ به عبارت دیگر،

$$(\forall x_i, y_j, z_k) P(X = x_i | Y = y_j, Z = z_k) = P(X = x_i | Z = z_k)$$

در این رابطه  $x_i \in V(X)$ ،  $y_j \in V(Y)$  و  $z_k \in V(Z)$  است. معمولاً عبارت بالا را به طور خلاصه به فرم  $P(X|Y,Z)=P(X|Z)$  می‌نویسیم. تعریف استقلال شرطی را می‌توان برای مجموعه‌ای از متغیرها تعمیم داد. می‌گوییم که مجموعه متغیرهای  $X_1 \dots X_l$  مستقل از مجموعه متغیرهای  $Y_1 \dots Y_m$  به شرط متغیرهای  $Z_1 \dots Z_l$  هستند اگر

$$P(X_1 \dots X_l | Y_1 \dots Y_m, Z_1 \dots Z_l) = P(X_1 \dots X_l | Z_1 \dots Z_l)$$

به رابطه‌ی این تعریف و تعریفمان از استقلال شرطی در دسته بندی کننده‌ی ساده‌ی بیز توجه کنید. دسته بندی کننده‌ی ساده بیز به طور شرطی مستقل بودن ویژگی  $A_1$  از ویژگی  $A_2$  را تعریف می‌کند. این تعریف به دسته بندی کننده‌ی ساده‌ی بیز اجازه می‌دهد که مقدار  $P(A_1, A_2 | V)$  را که در رابطه‌ی ۶.۲۰ آمده با استفاده از رابطه‌ی زیر محاسبه کند،

$$P(A_1, A_2 | V) = P(A_1 | A_2, V) P(A_2 | V) \quad (6.23)$$

$$= P(A_1 | V) P(A_2 | V) \quad (6.24)$$

رابطه‌ی ۶.۲۳ فقط فرم کلی حاصل از قانون احتمال جدول ۶.۱ است. رابطه‌ی ۶.۲۴ نیز از آن نتیجه شده است، زیرا که اگر  $A_1$  با معلوم بودن  $V$  از  $A_2$  مستقل باشد، پس طبق تعریف مستقل شرطی خواهیم داشت که،  $P(A_1 | A_2, V) = P(A_1 | V)$ .

### ۶.۱۱.۲ نمایش

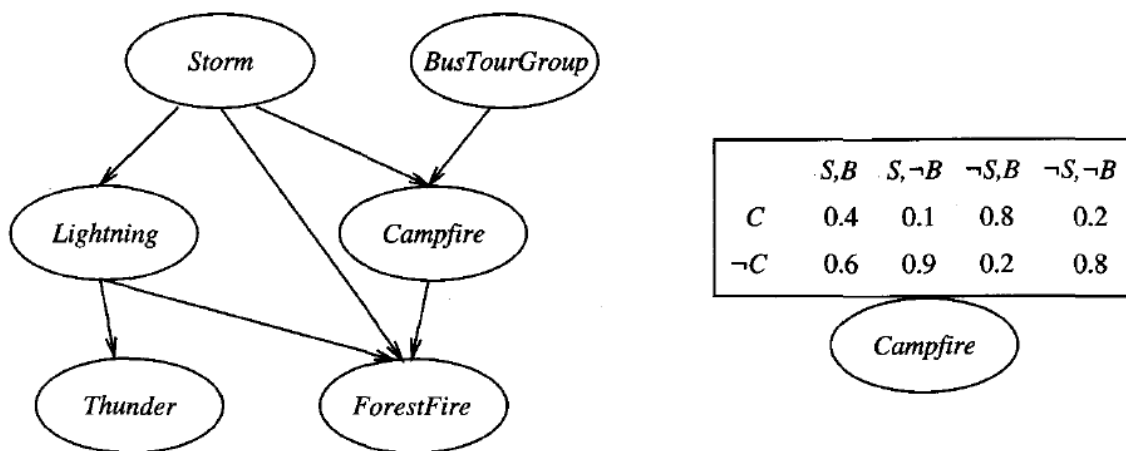
یک شبکه‌ی باور بیزی (که معمولاً به اختصار شبکه بیزی نامیده می‌شود) با توزیع احتمالات توأم مجموعه‌ای از متغیرها نمایش داده می‌شود. برای مثال، شبکه بیزی شکل ۶.۳ توزیع احتمال توأم متغیرهای منطقی Campfire، ForestFire، Thunder، Lightning، Storm و BusTourGroup را نشان می‌دهد. در کل، یک شبکه‌ی بیزی توزیع احتمال توأم را با استفاده از مشخص کردن مجموعه‌ای از فرض‌های استقلال شرطی (که با یک گراف بدون دور نمایش داده می‌شود) و مجموعه‌های از احتمالات شرطی هر کدام مشخص می‌کند. هر متغیر فضای توأم با یک گره در شبکه بیزی نشان داده می‌شود. برای هر متغیر دو نوع اطلاعات ذکر می‌شود، اول اینکه با فرض داشتن والدین

<sup>1</sup> Joint probability distribution

(در گراف) متغیر از متغیرهای غیر زیرینش مستقل شرطی است. زمانی می‌گوییم که  $X$  زیرینی<sup>۱</sup> برای  $Y$  است که مسیری مستقیم از  $Y$  به  $X$  باشد. دوم اینکه جدولی از احتمالات شرطی برای هر متغیر داده می‌شود که توزیع احتمال را برای مقدار متغیرهای بالایی<sup>۲</sup> مشخص می‌کند. احتمال توأم هر یک از مقادیر  $\langle y_1, \dots, y_n \rangle$  که مقداری از  $\langle Y_1 \dots Y_n \rangle$  است را می‌توان با استفاده از رابطه‌ی زیر محاسبه کرد،

$$P(y_1, \dots, y_n) = \prod_{i=1}^n P(y_i | \text{Parents}(Y_i))$$

در این رابطه  $\text{Parents}(Y_i)$  نماد مجموعه‌ای از بالایی‌های مستقیم  $Y_i$  در شبکه است. توجه داشته باشید که  $P(y_i | \text{Parents}(Y_i))$  دقیقاً مقدارهای ذخیره شده در جدول احتمالات شرطی مربوط به گره  $Y_i$  است.



شکل ۶.۳ یک شبکه‌ی باور بیزی.

شبکه‌ی سمت چپ مجموعه‌ای از فرض‌های استقلال شرطی را نشان می‌دهد. در کل، هر گره مستقل شرطی است از شروط غیر زیرینش<sup>۳</sup> با معلوم بودن شروط والدش مستقل است. برای هر گره جدول مقادیر شرطی‌ای وجود دارد که توزیع احتمال شرطی متغیرها را با معلوم بودن شروط والدینش در گراف مشخص می‌کند. جدول احتمال شرطی مربوط به گره *Campfire* که به طور خلاصه با  $C$  نمایش داده شده در سمت راست شکل آورده شده است، گره‌های *Storm* و *BusTourGroup* نیز به ترتیب به طور خلاصه با  $S$  و  $B$  نمایش داده شده‌اند.

برای تصور، شبکه‌ی بیزی شکل ۶.۳ توزیع احتمال توأم را برای متغیرهای منطقی *Storm*، *Lightning*، *Thunder*، *ForestFire*، *Campfire* و *BusTourGroup* نشان می‌دهد. گره‌ها و یال‌های<sup>۴</sup> شبکه نشان می‌دهد که *Campfire* با معلوم بودن والدینش، *Storm* و *BusTourGroup*، از *Lightning* و *Thunder* مستقل شرطی است. این بدین معناست که زمانی که مقدار *Storm* و *BusTourGroup* مشخص است متغیرهای *Lightning* و *Thunder* هیچ اطلاعات اضافه‌ای در مورد متغیر *Campfire* به ما نخواهند داد. برای مثال، سه داده‌ی اول سمت چپ جدول نشان می‌دهند که،

$$P(\text{Campfire} = \text{True} | \text{Storm} = \text{True}, \text{BusTourGroup} = \text{True}) = 0.4$$

<sup>1</sup> descendant

<sup>2</sup> predecessors

<sup>3</sup> nondescendants

<sup>4</sup> arc



توجه دارید که این جدول فقط مقادیر احتمال شرطی **Campfire** را با معلوم بودن مقادیر متغیرهای **Storm** و **BusTourGroup** می‌دهد. مجموعه‌ی موضعی جدول احتمالات شرطی برای تمامی متغیرها و مجموعه‌ای از فرض‌های استقلال شرطی که شبکه می‌گذارد، با هم توزیع احتمال شبکه روی کل فضای توأم را مشخص می‌کنند.

یکی از ویژگی‌های جذاب شبکه‌های باور بیزی این است که اجازه‌ی نمایش ساده‌ی اطلاعات علی<sup>۱</sup>، مثل این حقیقت که رعد و برق (lightning) باعث طوفان (Thunder) می‌شود، را به ما می‌دهد. در واژگان استقلال شرطی، این حقیقت را در شبکه با اینکه احتمال Thunder با معلوم بودن مقدار Lightning از بقیه‌ی متغیرها مستقل است نشان می‌دهیم. توجه داشته باشید که این فرض استقلال شرطی با یال‌های شبکه‌ی بیزی شکل ۶.۳ نشان داده شده است.

### ۶.۱۱.۳ استنتاج<sup>۲</sup>

ممکن است بخواهیم از شبکه‌های بیزی برای استنتاج مقدار چند متغیر (مثل **ForestFire**) با داشتن چند متغیر دیگر استفاده کنیم. البته، با دانستن اینکه کار ما با متغیرهای تصادفی است، در کل نیز نسبت دادن یک مقدار به متغیر هدف صحیح نخواهد بود. در اینجا ما بیشتر به استنتاج توزیع احتمال متغیر هدف علاقه داریم، توزیع احتمالی که مشخص می‌کند مقدار هدف با معلوم بودن مقادیر مفروض با چه احتمالی کدام مقدارش را می‌تواند داشته باشد. اگر مقادیر تمامی متغیرهای دیگر شبکه معلوم باشند مرحله‌ی استنتاج خیلی ساده خواهد شد. در حالت کلی‌تر ممکن است بخواهیم توزیع احتمال یک متغیر را با داشتن فقط زیر مجموعه‌ای از تمامی متغیرها (مثل **ForestFire**) استنتاج کنیم (ممکن است دو مقدار **Thunder** و **BusTourGroup** تنها مقادیر مشاهده شده‌ی ما باشند). در کل، یک شبکه‌ی بیزی را می‌توان برای محاسبه‌ی توزیع احتمال هر زیرمجموعه‌ای از متغیرهای شبکه با استفاده از معلوم بودن مقادیر هر زیر مجموعه‌ی دیگری از متغیرهای شبکه استفاده کرد.

استنتاج دقیق احتمالات در حالت کلی برای هر شبکه‌ی بیز دلخواه NP-hard است (Cooper 1990). متدهای عددی‌ای نیز برای استنتاج احتمالات در شبکه‌های بیزی، شامل متدهای استنتاج دقیق<sup>۳</sup> و متدهای تخمین استنتاج که دقت را فدای بازده می‌کنند ارائه شده‌اند. برای مثال، متدهای Monte Carlo راه‌حل‌های تخمینی را با استفاده از نمونه برداری تصادفی از توزیع احتمال متغیرهای مورد نظر را پیشنهاد می‌کنند (Pradham and Dagum 1996). در تئوری، حتی تخمین استنتاجی احتمالات شبکه‌ی بیزی را می‌توان NP-hard دانست (Dagum and Luby 1993). خوشبختانه در عمل، متدهای تخمینی در بسیاری از موارد مفید از آب در آمده‌اند. بحث متدهای استنتاج شبکه‌های بیزی در (Russell and Norvig 1995) و (Jensen 1996) آمده است.

### ۶.۱۱.۴ یادگیری شبکه‌های باور بیزی

آیا می‌توانیم الگوریتمی موثر برای یادگیری شبکه‌های باور بیزی از داده‌های آموزشی پیدا کنیم؟ این سؤال، زمینه‌ی مورد توجه اکثر تحقیقات فعلی است. تعریف مسئله‌های مختلفی را می‌توان برای این سؤال در نظر گرفت. ابتدا اینکه ساختار شبکه ممکن است دقیق مشخص باشد، یا ممکن است ساختار شبکه با توجه به داده‌های آموزشی انتخاب شود. دوم اینکه تمامی متغیرهای شبکه ممکن است در هر نمونه‌ی آموزشی مشهود و معلوم باشد یا بالعکس بعضی ممکن است بعضی متغیرها غیر قابل مشاهده باشند.

---

<sup>1</sup> causal knowledge

<sup>2</sup> inference

<sup>3</sup> exact inference

در حالتی که ساختار شبکه دقیق مشخص است، و فقط بعضی از مقادیر متغیرهای آن قابل مشاهده‌اند، مسئله‌ی یادگیری بسیار سخت‌تر خواهد بود. این مسئله به نحوی مشابه یادگیری وزن‌های واحد‌های پنهان شبکه‌های عصبی است، جایی که ورودی و خروجی شبکه مشخص است اما اطلاعاتی در مورد لایه‌ی پنهان شبکه در نمونه‌های آموزشی نیست. در واقع، (Russell 1995) فرایندی مشابه با شیب صعود ارائه داده است که احتمالات شرطی جدول را یاد می‌گیرد. این فرایند شیب صعود در فضایی از فرضیه‌ها که متناسب با مجموعه‌ای از تمامی حالت‌های ممکن احتمالات شرطی است برای یافتن مقادیر جدول احتمالات شرطی جستجو می‌کند. تابع‌ای که در طول شیب صعود ماکزیمم می‌شود احتمال  $P(D|h)$  داده‌های آموزشی  $D$  است با معلوم بودن فرضیه‌ی  $h$  است. طبق تعریف، این جستجو معادل جستجو برای محتمل‌ترین فرضیه برای مقادیر جدول است.

### ۶.۱۱.۵ آموزش شیب صعود برای شبکه‌های بیزی

قانون شیب صعودی که (Russell 1995) معرفی کرد، با حرکت به سمت افزایش  $\ln P(D|h)$  مقدار  $P(D|h)$  را با توجه به مقادیر جدول احتمالات شرطی شبکه‌ی بیز ماکزیمم می‌کند. فرض کنید  $w_{ijk}$  نماد تک داده‌ی ای از جدول‌های احتمالات شرطی شبکه باشد. در کل فرض کنید که  $w_{ijk}$  نماد احتمال شرطی اینکه متغیر شبکه‌ی  $Y_i$  مقدار  $y_{ij}$  را داشته باشد با معلوم بودن اینکه متغیر  $U_i$  مقدار  $u_{ik}$  را داشته باشد. برای مثال، اگر  $w_{ijk}$  داده‌ی گوشه‌ی بالا و سمت راست جدول احتمالات شرطی  $۶.۳$  باشد و  $Y_i$  نیز متغیر Campfire باشد و  $U_i$  نیز والدین آن یعنی  $\langle \text{Storm}, \text{BusTourGroup} \rangle$  و  $y_{ij} = \text{True}$  و  $u_{ik} = \langle \text{False}, \text{False} \rangle$  است. گرادیان  $\ln P(D|h)$  که با  $\frac{\partial \ln P(D|h)}{\partial w_{ijk}}$  برای هر  $w_{ijk}$  نشان داده می‌شود را همان طور که بعداً نیز نشان خواهیم داد می‌توان به صورت زیر محاسبه کرد،

$$\frac{\partial \ln P(D|h)}{\partial w_{ij}} = \sum_{d \in D} \frac{P(Y_i = y_{ij}, U_i = u_{ik} | d)}{w_{ijk}} \quad (6.25)$$

برای مثال، برای محاسبه‌ی هر یک از مقادیر مشتق  $\ln P(D|h)$  نسبت به داده‌ی گوشه‌ی بالا و راست جدول  $۶.۳$  باید مقدار  $P(\text{Campfire}=\text{True}, \text{Storm}=\text{False}, \text{BusTourGroup}=\text{False} | d)$  را برای هر یک از نمونه‌های آموزشی  $d$  در  $D$  محاسبه کنیم. زمانی که این متغیرهای برای نمونه‌ای مثل  $d$  مجهول است، لازم است که این احتمال را با استنتاج از متغیرهای دیگر آموزشی موجود  $d$  محاسبه کنیم. در واقع، این کمیت‌ها به راحتی از محاسبات استنتاجی انجام شده در اکثر شبکه‌های بیزی استخراج می‌شود، بنابراین یادگیری را می‌توان با هزینه‌ای کمی بیشتر، که از شبکه‌ی بیزی برای استنتاج و مدارک جدید متعاقباً بدست می‌آید.

در زیر از رابطه‌ی  $۶.۲۵$  که (Russell 1995) معرفی کرده بدست می‌آوریم. ادامه‌ی این قسمت را می‌توانید بدون از دست دادن پیوستگی قسمت‌ها در اولین خواند کتاب نخوانید. برای ساده سازی نماد، در این مشتق گیری از نماد  $P_h(d)$  برای نمایش  $P(D|h)$  استفاده خواهیم کرد. می‌خواهیم گرادیان این تابع را بیابیم پس باید رابطه‌ی  $\frac{\partial \ln P_h(D)}{\partial w_{ijk}}$  را به ازای تمامی مقادیر  $i$  و  $j$  و  $k$  محاسبه کنیم. با فرض اینکه نمونه‌های آموزشی  $d$  در مجموعه‌ی داده‌های  $D$  مستقل باشند، می‌توان نوشت،

$$\begin{aligned} \frac{\partial \ln P(D|h)}{\partial w_{ijk}} &= \frac{\partial}{\partial w_{ijk}} \ln \prod_{d \in D} P_h(d) \\ &= \sum_{d \in D} \frac{\partial \ln P_h(d)}{\partial w_{ijk}} \end{aligned}$$

$$= \sum_{d \in D} \frac{1}{P_h(d)} \frac{\partial P_h(d)}{\partial w_{ijk}}$$

مرحله‌ی آخر از رابطه‌ی  $\frac{\partial \ln f(x)}{\partial x} = \frac{1}{f(x)} \frac{\partial f(x)}{\partial x}$  نتیجه گیری شده است. حال می‌توان مقادیر متغیرهای  $Y_i$  و  $U_i = \text{Parents}(Y_i)$  را با استفاده از جمع روی مقادیر  $y_{ij}'$  و  $u_{ik}'$  معرفی کرد.

$$\begin{aligned} \frac{\partial \ln P(D|h)}{\partial w_{ijk}} &= \sum_{d \in D} \frac{1}{P_h(d)} \frac{\partial}{\partial w_{ijk}} \sum_{j', k'} P_h(d|y_{ij}', u_{ik}') P_h(y_{ij}', u_{ik}') \\ &= \sum_{d \in D} \frac{1}{P_h(d)} \frac{\partial}{\partial w_{ijk}} \sum_{j', k'} P_h(d|y_{ij}', u_{ik}') P_h(y_{ij}'|u_{ik}') P_h(u_{ik}') \end{aligned}$$

مرحله‌ی آخر از قانون احتمال جدول ۶.۱ نتیجه گیری شده است. حال جمع سمت راستی رابطه‌ی بالا را در نظر بگیرید، با توجه به تعریف  $w_{ijk} \equiv P_h(y_{ij}|u_{ik})$  خواهیم داشت که تمامی جملات جز جمله‌ی  $j'=j$  و  $i'=i$  صفر خواهند بود پس داریم،

$$\begin{aligned} \frac{\partial \ln P(D|h)}{\partial w_{ijk}} &= \sum_{d \in D} \frac{1}{P_h(d)} \frac{\partial}{\partial w_{ijk}} \sum_{j', k'} P_h(d|y_{ij}, u_{ik}) P_h(y_{ij}|u_{ik}) P_h(u_{ik}) \\ &= \sum_{d \in D} \frac{1}{P_h(d)} \frac{\partial}{\partial w_{ijk}} \sum_{j', k'} P_h(d|y_{ij}, u_{ik}) w_{ijk} P_h(u_{ik}) \\ &= \sum_{d \in D} \frac{1}{P_h(d)} P_h(d|y_{ij}, u_{ik}) P_h(u_{ik}) \end{aligned}$$

با استفاده از قضیه‌ی بیز برای مقدار  $P_h(d|y_{ij}, u_{ik})$  داریم،

$$\begin{aligned} \frac{\partial \ln P(D|h)}{\partial w_{ijk}} &= \sum_{d \in D} \frac{1}{P_h(d)} \frac{P_h(y_{ij}, u_{ik}|d) P_h(d) P_h(u_{ik})}{P_h(y_{ij}, u_{ik})} \\ &= \sum_{d \in D} \frac{P_h(y_{ij}, u_{ik}|d) P_h(u_{ik})}{P_h(y_{ij}, u_{ik})} \\ &= \sum_{d \in D} \frac{P_h(y_{ij}, u_{ik}|d)}{P_h(y_{ij}|u_{ik})} \\ &= \sum_{d \in D} \frac{P_h(y_{ij}, u_{ik}|d)}{w_{ijk}} \end{aligned} \tag{6.26}$$

بدین صورت مشتق رابطه‌ی ۶.۲۵ محاسبه می‌شود. قبل از رفتن به سراغ قانون فرایند شیب صعود باید در نظر گرفت که باید پس از تغییر مقادیر  $w_{ijk}$  آن‌ها همچنان در بازه‌ی  $[0,1]$  باقی بمانند تا احتمالات معتبری باشند. از طرف دیگر باید مقدار  $\sum_j w_{ijk}$  برای تمامی مقادیر  $i$  و  $k$ ، ۱ باقی بماند. این شروط را می‌توان با تغییر دو مرحله‌ای وزن‌ها اعمال کرد، ابتدا هر  $w_{ijk}$  را با توجه به شیب صعود تغییر می‌دهیم،

$$w_{ijk} \leftarrow w_{ijk} + \eta \sum_{d \in D} \frac{P_h(y_{ij}, u_{ik} | d)}{w_{ijk}}$$

در این رابطه  $\eta$  ثابت کوچکی به نام ضریب یادگیری است. در مرحله‌ی دوم وزن‌ها را نرمالیزه می‌کنیم تا در شروط بالا صدق کنند. همان‌طور که Russell نیز توضیح داده است این فرایند به محتمل‌ترین فرضیه‌ی نسبی برای احتمالات شرطی در شبکه بیز میل خواهد کرد.

مثل دیگر روش‌های بر پایه‌ی شیب صعود، این الگوریتم نیز فقط تضمین می‌کند که راه حل بهینه‌ی موضعی پیدا کند. جایگزین دیگر موجود برای شیب صعود الگوریتم EM است که در قسمت ۶.۱۲ توضیح داده می‌شود، این الگوریتم نیز راه حلی بهینه موضعی پیدا خواهد کرد.

### ۶.۱۱.۶ یادگیری ساختار شبکه‌ی بیزی

یادگیری شبکه‌های بیزی هنگامی که ساختار شبکه به دقت معلوم نیست نیز پیچیده است. (Cooper and Herskovits 1992) روشی Bayesian scoring metric برای انتخاب میان شبکه‌های مختلف ارائه می‌کنند. آن‌ها همچنین جستجویی ابتکاری به نام الگوریتم K2 برای یادگیری ساختار شبکه در شرایطی که داده‌ها به طور کامل قابل مشاهده‌اند ارائه می‌کنند. مشابه اکثر الگوریتم‌های یادگیری ساختار شبکه‌ی بیز، K2 نیز از جستجویی حریصانه که پیچیدگی فرضیه را فدای دقت روی داده‌های آموزشی می‌کند استفاده می‌کند. در آزمایشی به K2 مجموعه‌ای از 3,000 نمونه‌ی آموزشی تصادفی از شبکه‌ی بیزی‌ای معلومی با ۳۷ گره و ۴۶ یال داده شد. این شبکه‌ی خاص مشکلات بیهوشی را در یک اتاق جراحی بیمارستان توصیف می‌کرد. علاوه بر این داده‌ها، به برنامه‌ی ترتیبی اولیه‌ای از ۳۷ متغیری که سازگار با قسمتی از ترتیب وابستگی متغیرها در شبکه‌ی واقعی بود نیز داده شد. این برنامه در تشخیص شبکه‌ی بیزی درست تقریباً موفق شد، این شبکه یالی اضافه و یالی دیگر کمتر از شبکه‌ی اصلی داشت.

روش‌های مبتنی بر قیود<sup>۱</sup> نیز در یادگیری ساختار شبکه‌های بیزی نیز پیشنهاد شده است (Sprites et al. 1993). این روش‌ها روابط استقلال و وابستگی را از داده‌ها استنتاج کرده و از آن‌ها برای ساخت شبکه‌های بیزی استفاده می‌کنند. بررسی مربوطه‌ی روش‌های فعلی یادگیری ساختار شبکه‌های بیزی در (Heckerman 1995) و (Buntine 1994) آورده شده است.

## ۶.۱۲ الگوریتم EM


در بسیاری از تعریف مسئله‌های کاربردی، فقط یک زیر مجموعه از ویژگی‌های نمونه‌ها قابل مشاهده است. برای مثال، در یادگیری یا استفاده‌ی شبکه‌ی باور بیزی‌ای که در جدول ۶.۳ آورده شد، ممکن است فقط داده‌های نظیر یک زیر مجموعه از متغیرهای شبکه مثل زیر مجموعه‌ی Storm, Lightning, Thunder, ForestFire, Campfire, BusTourGroup را داشته باشیم. روش‌های بسیاری برای کنترل این مشکل پیشنهاد شده است، همان‌طور که در فصل ۳ نیز دیدید، اگر بعضی متغیرها در بعضی موارد غیر قابل مشاهده و در

<sup>1</sup> constraint-based

بعضی موارد قابل مشاهده باشند، می‌توان از نمونه‌های آموزشی‌ای که این مقدار را دارند برای پیش‌بینی این ویژگی در دیگر نمونه‌ها استفاده کرد. در این بخش به الگوریتم EM که در یادگیری با وجود ویژگی‌های مجهول کاربرد زیاد دارد می‌پردازیم. از الگوریتم EM می‌توان حتی برای متغیرهایی که هیچ وقت به طور مستقیم قابل مشاهده نیستند نیز استفاده کرد، اما لازم است که فرم کلی توزیع احتمال حاکم بر این متغیرها معلوم باشد. الگوریتم EM برای آموزش شبکه‌های باور بیزی (برای اطلاعات بیشتر به Heckerman 1995 رجوع کنید) و شبکه‌های توابع شعاعی<sup>۱</sup> که در قسمت ۸.۴ توضیح داده شد به کار می‌روند. الگوریتم EM پایه‌ی بسیاری از الگوریتم‌های خوشه‌یابی<sup>۲</sup> (Cheeseman 1988) و همچنین پایه‌ی الگوریتم‌های پرکاربرد Baum-Welch forward-backward برای یادگیری مدل‌های نیمه مشهود مارکوف<sup>۳</sup> است (Rabiner 1989).

### ۶.۱۲.۱ تخمین میانگین $k$ توزیع نرمال

راحت‌ترین راه معرفی الگوریتم EM از طریق یک مثال است. مسئله‌ای را در نظر بگیرید که در آن داده‌های آموزشی  $D$  مجموعه‌ای از نمونه‌هایی است که از طریق توزیعی که ترکیب  $k$  توزیع نرمال<sup>۴</sup> است بدست آمده‌اند. این تعریف مسئله برای  $k=2$  در شکل ۶.۴ آمده است، در این شکل نمونه‌ها نقاط روی محور  $x$  هستند. هر نمونه از فرایندی دو مرحله‌ای بدست می‌آید. ابتدا به تصادف یکی از  $k$  توزیع نرمال انتخاب می‌شود. سپس بر اساس آن توزیع نرمال نمونه‌ی  $x_i$  ایجاد می‌گردد. این فرایند برای ایجاد مجموعه‌ای از نمونه‌های آموزشی همان طور که در شکل نشان داده شده است تکرار خواهد شد. برای ساده‌سازی بحث، حالتی را بررسی می‌کنیم که احتمال تمامی توزیع‌های نرمال در مرحله‌ی اول یکسان است و تمامی توزیع‌های نرمال واریانس مشترک  $\sigma^2$  دارند. هدف یادگیری پیدا کردن فرضیه‌ای به شکل  $h = \langle \mu_1, \dots, \mu_k \rangle$  است که میانگین‌های  $k$  توضیح احتمال را توصیف کند. در کار یادگیری سعی می‌کنیم تا محتمل‌ترین فرضیه را پیدا کنیم؛ فرضیه‌ای که  $p(D|h)$  را ماکزیمم کند.



<sup>1</sup> Radial basis function network

<sup>2</sup> clustering

<sup>3</sup> Partially Observable Markov Models

<sup>4</sup> Mixed Gaussian distribution

شکل ۶.۴ نمونه‌های حاصل از ترکیب دو توزیع نرمال با واریانس  $\sigma$  یکسان.

نمونه‌ها با تقاطعی روی محور  $X$  نشان داده شده‌اند. اگر میانگین توزیع‌های نرمال نامعلوم باشد، الگوریتم EM را می‌توان برای جستجوی محتمل‌ترین مقدار تخمین آن‌ها به کاربرد.

توجه دارید که محاسبه‌ی محتمل‌ترین فرضیه برای میانگین یک توزیع نرمال با داشتن نمونه‌های  $x_1, x_2, \dots, x_m$  فقط حالت خاصی از مسئله‌ای است که در قسمت ۶.۴ بحث شد، در رابطه‌ی ۶.۶ نشان دادیم که محتمل‌ترین فرضیه، فرضیه‌ای است که مجموع خطاهای مربعی را برای تمامی  $m$  نمونه مینیمم می‌کند. اگر رابطه‌ی ۶.۶ را با توجه به نماد گذاری جدید بازنویسی کنیم، خواهیم داشت،

$$\mu_{ML} = \arg \max_{\mu} \sum_{i=1}^m (x_i - \mu)^2 \quad (6.27)$$

در چنین شرایطی مجموع خطاهای مربعی با تساوی زیر مینیمم خواهد شد،

$$\mu_{ML} = \frac{1}{m} \sum_{i=1}^m x_i \quad (6.28)$$

با وجود این وجود مسئله‌ی ما درباره‌ی ترکیبی از توابع نرمال است و تشخیص اینکه نمونه‌ها از کدام توزیع بدست آمده‌اند نیز ممکن نیست. بنابراین، با صورت مثالی کلی از مسئله‌هایی که متغیرهای پنهان دارند مواجهیم. در مثال شکل ۶.۴، می‌توان توضیح کامل مربوطه‌ی هر نمونه را به شکل سه تایی مرتب  $\langle x_i, Z_{i1}, Z_{i2} \rangle$  در نظر گرفت، در این سه تایی مرتب  $x_i$  مقدار مشاهده شده‌ی آمین نمونه است و دو مقدار  $Z_{i1}, Z_{i2}$  مشخص می‌کند که کدام یک از دو توزیع نرمال برای تولید این نمونه به کار رفته‌اند. در کل،  $Z_{ij}$  زمانی یک است که نمونه از توزیع نرمال  $j$  ام بدست آمده است و در غیر این صورت صفر خواهد بود. در اینجا متغیر  $x_i$  قابل مشاهده و متغیرهای  $Z_{i1}, Z_{i2}$  متغیرهای پنهان هستند. اگر مقادیر متغیرهای  $Z_{i1}, Z_{i2}$  قابل مشاهده بودند می‌شد از رابطه‌ی ۶.۲۷ برای پیدا کردن  $\mu_1$  و  $\mu_2$  استفاده کرد، حال چون این متغیرها قابل مشاهده نیستند از الگوریتم EM استفاده خواهیم کرد.

در این مثال، پیدا کردن  $k$  میانگین، الگوریتم EM به تخمین مقادیر  $Z_{ij}$  با معلوم بودن فرضیه‌ی فعلی  $\langle \mu_1, \dots, \mu_k \rangle$  می‌پردازد و سپس مقادیر محتمل‌ترین فرضیه‌ها را با توجه به این مقادیر تصادفی برای متغیرهای پنهان دوباره محاسبه می‌کند. ابتدا این مثال را در الگوریتم EM توصیف حل می‌کنیم، الگوریتم EM را در حالت کلی بیان خواهیم کرد.

برای شکل ۶.۴ الگوریتم EM ابتدا مقدار اولیه‌ی فرضیه را به  $h = \langle \mu_1, \mu_2 \rangle$  که در آن  $\mu_1$  و  $\mu_2$  دو مقدار دلخواه هستند مقدار دهی اولیه می‌کند. سپس فرضیه‌ی  $h$  را با تکرار حلقه‌ی دو مرحله‌ای زیر ارزیابی می‌کند، این حلقه تا زمانی که فرایند به مقدار ثابتی از  $h$  همگرا شود حلقه تکرار خواهد شد.

**مرحله ۱:** مقدار امید  $E[Z_{ij}]$  را برای هر متغیر پنهان  $Z_{ij}$  با فرض درستی فرضیه‌ی  $h = \langle \mu_1, \mu_2 \rangle$  محاسبه کن.

**مرحله ۲:** محتمل‌ترین فرضیه‌ی جدید  $h' = \langle \mu_1', \mu_2' \rangle$  را با فرض اینکه تمامی مقادیر  $Z_{ij}$  مقدار امید  $E[Z_{ij}]$  که در مرحله ۱ محاسبه شد است را محاسبه کن. سپس فرضیه‌ی  $h = \langle \mu_1, \mu_2 \rangle$  را با فرضیه‌ی  $h' = \langle \mu_1', \mu_2' \rangle$  جایگزین کن.

بیاپید نحوه‌ی پیاده سازی هر یک از مراحل را در عمل بررسی کنیم. مرحله‌ی اول باید مقدار امید هر یک از  $Z_{ij}$  را محاسبه کند. این مقدار  $E[Z_{ij}]$  فقط احتمال نمونه‌ی  $x_i$  است که از طریق  $z$  آمین توزیع نرمال ایجاد شده است.

$$E[Z_{ij}] = \frac{p(x = x_i | \mu = \mu_j)}{\sum_{n=1}^2 p(x = x_i | \mu = \mu_n)}$$

$$= \frac{e^{-\frac{1}{2\sigma^2}(x_i - \mu_j)^2}}{\sum_{n=1}^2 e^{-\frac{1}{2\sigma^2}(x_i - \mu_n)^2}}$$

مرحله‌ی اول با بکار گیری مقادیر فعلی  $\mu_1, \mu_2 <$  و مقدار فعلی  $x_i$  نتیجه گیری شده است.

در مرحله‌ی دوم مقداری که برای  $E[Z_{ij}]$  در مرحله‌ی اول محاسبه شد استفاده می‌شود تا محتمل‌ترین فرضیه  $h' = < \mu_1', \mu_2' >$  محاسبه شود. همان طور که بعداً نیز بحث خواهیم کرد، محتمل‌ترین فرضیه در این حالت با رابطه‌ی زیر محاسبه می‌شود،

$$\mu_j \leftarrow \frac{\sum_{i=1}^m E[Z_{ij}] x_i}{\sum_{i=1}^m E[Z_{ij}]}$$

توجه دارید که این رابطه تشابه بسیاری به رابطه‌ی ۶.۲۸ برای تخمین مقدار  $\mu$  برای یک توزیع نرمال دارد. در رابطه‌ی جدید فقط میانگین وزن دار  $\mu_j$  هاست، وزن هر  $\mu_j$  مقدار  $E[Z_{ij}]$  که از  $z$  آمین توزیع نرمال بدست آمده است.

الگوریتم بالا برای تخمین میانگین‌های ترکیب  $k$  توزیع نرمال با روش الگوریتم EM است: فرضیه‌ی فعلی برای تخمین متغیرهای نا مشهود استفاده می‌شود، سپس مقدار امید این متغیرها برای محاسبه‌ی فرضیه‌ی بهتری به کار می‌رود. می‌توان اثبات کرد که با هر دور اجرای حلقه الگوریتم EM میزان محتمل بودن  $P(D|h)$  را بیشتر می‌کند، مگر اینکه آن یک ماکزیمم نسبی باشد. پس الگوریتم EM در انتها به یک ماکزیمم موضعی برای محتمل بودن  $\mu_1, \mu_2 <$  میل خواهد کرد.

## ۶.۱۲.۲ حالت کلی الگوریتم EM

در بالا الگوریتم EM را برای مسئله‌ی تخمین میانگین‌های ترکیب توزیع احتمال‌های نرمال بیان کردیم. در حالت کلی‌تر، الگوریتم EM را می‌توان در بسیاری از تعریف مسئله‌ها که در آن‌ها بحث از تخمین مجموعه‌ای از پارامترهای  $\theta$  که توضیح احتمال حاکم را توصیف می‌کنند با استفاده از قسمتی از داده‌ها که قابل شهود است به کاربرد. در مثال دو میانگین بالا پارامترهای مورد علاقه  $\theta = < \mu_1, \mu_2 >$  است، داده‌های کامل سه تایی مرتب‌های  $< x_i, z_{i1}, z_{i2} >$  هستند که فقط  $x_i$  قابل مشاهده است. در کل اگر  $X = \{x_1, \dots, x_m\}$  داده‌های مشاهده شده در مجموعه‌ای از  $m$  نمونه‌ی مستقل و  $Z = \{z_1, \dots, z_m\}$  نیز داده‌های غیر قابل مشاهده باشد در این نمونه‌های آموزشی  $Y = X \cup Z$  کل داده‌ها خواهد بود. توجه دارید که با  $Z$  می‌توان به دید متغیر تصادفی‌ای که توزیع احتمالش به پارامترهای نامعلوم  $\theta$  و داده‌های مشاهده شده‌ی  $X$  وابسته است نگاه کرد. به طور مشابه،  $Y$  نیز متغیری تصادفی است، زیرا که توسط متغیر تصادفی  $Z$  تعریف می‌شود. در ادامه‌ی این بخش فرم کلی الگوریتم EM را توضیح خواهیم داد. از  $h$  برای نمایش مقادیر مفروض فعلی از پارامترهای  $\theta$  و از  $h'$  برای فرضیه‌ی بازبینی شده‌ی هر حلقه الگوریتم EM استفاده خواهیم کرد.

الگوریتم EM فضای فرضیه‌ی محتمل‌ترین فرضیه‌ها  $h'$  را برای پیدا کردن  $h'$  که مقدار  $E[\ln P(Y|h')|h]$  را ماکزیمم کند جستجو می‌کند. این مقدار امید برای تمامی توزیع احتمالات  $Y$  که توسط پارامترهای نامعلوم مشخص می‌گردد محاسبه می‌شود. بیایید مفهوم دقیق این مقدار امید را با هم بررسی کنیم. ابتدا اینکه  $P(Y|h')$  محتمل بودن داده‌های کامل  $Y$  را با شرط معلوم بودن  $h'$  نشان می‌دهد. پس پیدا کردن فرضیه‌ی  $h'$  به قسمی که تابعی از این معیار را ماکزیمم کند منطقی خواهد بود. دوم اینکه، ماکزیمم کردن لگاریتم این کمیت،  $\ln P(Y|h')$  نیز  $P(Y|h')$  را ماکزیمم می‌کند (همان طور که پیش‌تر نیز گفته بودیم). سوم اینکه ما مقدار امید  $E[\ln P(Y|h')]$  را برای اینکه داده‌های کامل  $Y$  خود متغیری تصادفی است معرفی می‌کنیم. با دانستن اینکه داده‌های کامل  $Y$  ترکیبی از داده‌های مشاهده شده‌ی  $X$  و داده‌های مشاهده نشده‌ی  $Z$  است، باید میانگین را برای مقادیر ممکن  $Z$  های مشاهده نشده با وزن متناسب با احتمالشان محاسبه کنیم. به عبارت دیگر، مقدار امید  $E[\ln P(Y|h')]$  بر روی توزیع احتمالات تصادفی  $Y$  محاسبه می‌شود. توزیع  $Y$  توسط مقادیر کاملاً معلوم  $X$  و توزیع احتمال حاکم بر  $Z$  تعیین می‌شود.

توزیع احتمال حاکم بر  $Y$  چیست؟ در کل این توزیع را نمی‌دانیم، زیرا که این توزیع با پارامترهای  $\theta$  که می‌خواهیم تخمین بزنیم تعیین می‌شود. بنابراین، الگوریتم EM از فرضیه‌ی فعلی  $h$  به جای پارامترهای واقعی  $\theta$  برای تخمین توزیع احتمال حاکم بر  $Y$  استفاده می‌کند. بیایید تابعی به فرم  $Q(h'|h)$  تعریف کنیم که مقدار  $E[\ln P(Y|h')|h]$  را به عنوان تابعی از  $h'$  با فرض  $\theta=h$  و داشتن قسمت قابل مشاهده‌ی  $X$  از کل داده‌های  $Y$  بیان کند.

$$Q(h'|h) = E[\ln P(Y|h')|h, X]$$

این تابع  $Q$  را به فرم  $Q(h'|h)$  می‌نویسیم تا نشان دهد که این تابع با این فرض تعریف شده که فرضیه‌ی فعلی  $h$  با  $\theta$  مساوی است. در فرم کلی، الگوریتم EM تا رسیدن به همگرایی دو مرحله‌ی زیر را تکرار می‌کند:

**مرحله‌ی ۱:** مرحله‌ی تخمین (E): مقدار  $Q(h'|h)$  را با استفاده از فرضیه‌ی فعلی  $h$  و داده‌های مشاهده شده‌ی  $X$  برای تخمین توزیع احتمال روی  $Y$  محاسبه کن.

$$Q(h'|h) = E[\ln p(Y|h') | h, X]$$

**مرحله‌ی ۲:** مرحله‌ی ماکزیمم سازی (M): فرضیه‌ی  $h$  را با فرضیه‌ی  $h'$  که مقدار  $Q$  را ماکزیمم می‌کند جایگزین کن.

$$h \leftarrow \arg \max_{h'} Q(h'|h)$$

اگر تابع  $Q$  پیوسته باشد، الگوریتم EM به نقطه تعادل محتمل‌ترین فرضیه‌ی  $P(Y|h')$  میل خواهد کرد. اگر این تابع محتمل بودن فقط یک ماکزیمم داشته باشد، EM نیز به همان تخمین همان ماکزیمم مطلق برای  $h'$  میل خواهد کرد. در غیر این صورت، این الگوریتم تضمین می‌کند تا به ماکزیمی موضعی میل کند. در چنین شرایطی، EM محدودیت‌های الگوریتم‌های دیگری که از جستجوی شیب نزول استفاده می‌کنند را خواهد داشت، در فصل ۴ توضیح کاملی در مورد این مشکلات و راه حل‌های آن‌ها آورده شده است.

### ۶.۱۲.۳ اشتقاق الگوریتم $k$ میانگین

برای تصور بهتر کلی الگوریتم EM، بیایید مشتق الگوریتم آورده شده در قسمت ۶.۱۲.۱ برای تخمین میانگین‌های  $k$  توزیع نرمال را بررسی کنیم. همان طور که در بالا نیز توضیح داده شد، مسئله‌ی تخمین  $k$  میانگین، مسئله‌ی تخمین پارامترهای  $\mu_1 \dots \mu_k = \theta$  است که



میانگین  $k$  توزیع نرمال تعریف می‌شوند. داده‌های مشاهده شده‌ی  $X = \{< x_i >\}$  به ما داده شده‌اند. در این مسئله متغیرهای پنهان  $Z = \{z_{i1}, \dots, z_{ik}\}$  هستند که مشخص می‌کنند که نمونه با استفاده از کدام توزیع ایجاد شده است.

برای به کار بردن EM ابتدا باید مشتق  $Q(h|h')$  را برای این تخمین  $k$  میانگین پیدا کرد. بیایید ابتدا مشتق رابطه‌ی  $p(Y|h')$  را محاسبه کنیم. توجه دارید که احتمال  $p(y_i|h')$  برای یک تک نمونه‌ی  $y_i = < x_i, z_{i1}, \dots, z_{ik} >$  از داده‌های کامل را می‌توان به صورت زیر دقیق محاسبه کرد.

$$p(y_i|h') = p(x_i, z_{i1}, \dots, z_{ik}|h') = \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{1}{2\sigma^2} \sum_{j=1}^k z_{ij}(x_i - \mu'_j)^2}$$

توجه داشته باشید که از تمامی  $z_{ij}$  ها فقط یکی ۱ است و بقیه ۰ هستند. بنابراین این رابطه توزیع احتمال  $x_i$  را بر اساس توزیع نرمال انتخابی نشان می‌دهد. با داشتن احتمال تک نمونه،  $p(y_i|h')$ ، لگاریتم احتمال  $P(Y|h')$  برای تمامی  $m$  نمونه در داده‌ها به صورت زیر خواهد بود،

$$\begin{aligned} \ln P(Y|h') &= \ln \prod_{i=1}^m p(y_i|h') \\ &= \sum_{i=1}^m \ln p(y_i|h') \\ &= \sum_{i=1}^m \left( \ln \frac{1}{\sqrt{2\pi\sigma^2}} - \frac{1}{2\sigma^2} \sum_{j=1}^k z_{ij}(x_i - \mu'_j)^2 \right) \end{aligned}$$

حال می‌توان بالاخره مقدار امید  $\ln P(Y|h')$  را بر اساس توزیع احتمال حاکم بر  $Y$  یا به طور مشابه توزیع احتمال حاکم بر متغیرهای غیر قابل مشاهده‌ی  $Y$  ( $z_{ij}$  ها) محاسبه کرد. توجه دارید که عبارت بالا برای  $\ln P(Y|h')$  تابعی خطی از  $z_{ij}$  هاست. در کل برای هر تابع  $f(z)$  که تابعی خطی از  $Z$  است رابطه‌ی زیر درست است،

$$E[f(z)] = f(E[z])$$

با استفاده از حقیقت بالا درباره‌ی توابع خطی می‌توان نوشت،

$$\begin{aligned} E[\ln P(Y|h')] &= E \left[ \sum_{i=1}^m \left( \ln \frac{1}{\sqrt{2\pi\sigma^2}} - \frac{1}{2\sigma^2} \sum_{j=1}^k z_{ij}(x_i - \mu'_j)^2 \right) \right] \\ &= \sum_{i=1}^m \left( \ln \frac{1}{\sqrt{2\pi\sigma^2}} - \frac{1}{2\sigma^2} \sum_{j=1}^k E[z_{ij}](x_i - \mu'_j)^2 \right) \end{aligned}$$

برای خلاصه سازی تابع  $Q(h'|h)$  در مسئله‌ی  $k$  میانگین به صورت زیر است،

$$Q(h'|h) = \sum_{i=1}^m \left( \ln \frac{1}{\sqrt{2\pi}\sigma^2} - \frac{1}{2\sigma^2} \sum_{j=1}^k E[z_{ij}](x_i - \mu'_j)^2 \right)$$

در این رابطه  $h' = \langle \mu'_1, \dots, \mu'_k \rangle$  و  $E[z_{ij}]$  نیز بر اساس فرضیه‌ی فعلی  $h$  و داده‌های مشاهده‌شده‌ی  $X$  محاسبه می‌شود. همان‌طور که قبلاً نیز نشان دادیم،

$$E[z_{ij}] = \frac{e^{-\frac{1}{2\sigma^2}(x_i - \mu_j)^2}}{\sum_{n=1}^k e^{-\frac{1}{2\sigma^2}(x_i - \mu_n)^2}} \quad (6.29)$$

بنابراین مرحله اول (تخمین) الگوریتم EM تابع  $Q$  را بر اساس تخمین  $E[z_{ij}]$  تعریف می‌کند. مرحله‌ی دوم (ماکزیمم‌سازی) نیز مقادیر  $\mu'_1, \dots, \mu'_k$  را پیدا خواهد کرد که این تابع  $Q$  را ماکزیمم کند. در مثال فعلی داریم که،

$$\begin{aligned} \arg \max_{h'} Q(h'|h) &= \arg \max_{h'} \sum_{i=1}^m \left( \ln \frac{1}{\sqrt{2\pi}\sigma^2} - \frac{1}{2\sigma^2} \sum_{j=1}^k E[z_{ij}](x_i - \mu'_j)^2 \right) \\ &= \arg \min_{h'} \sum_{i=1}^m \sum_{j=1}^k E[z_{ij}](x_i - \mu'_j)^2 \end{aligned} \quad (6.30)$$

محتمل‌ترین فرضیه اینجا مجموعی وزن دار از خطاهای مربعی را مینیمم می‌کند، در این خطا مربع اختلاف  $x_i$  ها با  $\mu'_j$  با وزن  $E[z_{ij}]$  مینیمم می‌شود. کمیت رابطه‌ی ۶.۳۰ با قرار دادن مقادیر  $\mu'_j$  به صورت زیر مینیمم می‌شود،

$$\mu_j \leftarrow \frac{\sum_{i=1}^m E[z_{ij}]x_i}{\sum_{i=1}^m E[z_{ij}]} \quad (6.31)$$

توجه دارید که روابط ۶.۲۹ و ۶.۳۱ دو مرحله‌ی الگوریتم  $k$  میانگین قسمت ۶.۱۲.۱ را توصیف می‌کنند.

## ۶.۱۳ خلاصه و منابع برای مطالعه‌ی بیشتر

این فصل شامل موارد زیر می‌شود:

- متدهای بیزی پایه ای برای متدهای یادگیری احتمالی‌ای با دانش قبلی یا فرض آن درباره‌ی احتمالات ثانویه فرضیه‌ها و احتمال مشاهده‌ی نمونه‌ها است. متدهای بیزی نسبت دادن احتمال ثانویه به هر فرضیه‌ی ممکن را بر اساس احتمالات اولیه‌ی مفروض را ممکن می‌سازند.
- از متدهای بیزی می‌توان برای تعیین محتمل‌ترین فرضیه با فرض داشتن داده‌ها استفاده کرد، فرضیه‌ی MAP. این فرضیه‌ی از این جهت بهینه است که از تمامی فرضیه‌های دیگر محتمل‌تر است.

- دسته بندی کننده‌ی بهینه‌ی بیز پیش بینی تمامی فرضیه های ممکن را با احتمالات ثانویه‌شان ترکیب کرده محتمل‌ترین دسته بندی هر نمونه را به ما می‌دهد.
  - دسته بندی کننده‌ی ساده‌ی بیز متد یادگیری بیزی است که در بسیاری از موارد کاربردی مفید شناخته شده است. به این الگوریتم به این دلیل "ساده" می‌گویند که شامل این فرض ساده کننده می‌باشد که ویژگی‌های نمونه‌ها با فرض داشتن دسته بندی نمونه مستقلند. با این فرض، دسته بندی کننده‌ی ساده‌ی بیز یک فرضیه MAP را خروجی خواهد داد. حتی زمانی که این فرض هم درست نیست هم، مثل حالتی که از این دسته بندی کننده برای دسته بندی متون استفاده کردیم، گاهی دسته بندی کننده‌ی ساده بیزی موثر است. شبکه های بیزی نمایش بهتری نسبت به مجموعه فرض ها استقلال در بین زیر مجموعه ای از ویژگی ها دارند.
  - چهار چوب استدلال بیزی می‌تواند پایه مناسبی برای بررسی متدهای یادگیری بخصوص که مستقیماً از قضیه‌ی بیز استفاده نمی‌کنند باشد. برای مثال در شرایط خاص می‌توان نشان داد که زمانی که تابع هدف حقیقی مقداری را با مینیمم کردن مجموع خطاهای مربعی یاد می‌گیریم، محتمل‌ترین فرضیه را یاد می‌گیریم.
  - قانون حداقل طول توضیح توصیه می‌کند که فرضیه‌هایی را انتخاب کنیم که کمترین طول توضیح برای فرضیه به اضافه‌ی طول توضیحات همراه فرضیه را داشته باشد. قضیه‌ی بیز و نتایج پایه ای تئوری اطلاعات را می‌توان برای ایجاد دلیلی برای این قانون به کار برد.
  - در بسیاری از کارهای یادگیری عملی، بعضی از ویژگی‌های نمونه های ممکن است قابل مشاهده نباشد. الگوریتم EM روش کلی‌ای برای یادگیری در حضور متغیر های غیر مشهود ارائه می‌کند. این الگوریتم کار خود را با مجموعه ای از فرضیه های دلخواه آغاز می‌کند. سپس مقدار امید متغیر نامشهود را محاسبه کرده (با این فرض که فرضیه فعلی درست است). و سپس مقدار محتمل‌ترین فرضیه را محاسبه می‌کند (با فرض اینکه متغیر های پنهان همان مقادیر امید محاسبه شده‌ی این مرحله هستند). تکرار این فرایند به یک ماکزیمم نسبی در احتمال درستی فرضیه میل می‌کند و مقادیر متغیر های پنهان را نیز تقریب می‌زند.
- کتاب آموزشی ساده‌ی بسیاری درباره‌ی احتمالات و آمار مثل Casella and Berger (1990) نوشته شده است. کتاب مرجع سریع بسیاری نیز مثل Maisel (1971) و Spiegel (1991) نوشته شده، این کتاب نماد گذاری آمار و احتمال متناسب با یادگیری ماشین را نیز ارائه می‌کنند.
- بسیاری از نمادگذاری‌های ابتدایی دسته بندی کننده های بیزی و دسته بندی کننده های مینیم خطای مربعی در Duda and Hart (1973) بررسی شده است. Domingos and Pazzani (1996) شرایط اینکه دسته بندی کننده‌ی ساده‌ی بیز، دسته بندی بهینه را خروجی می‌دهد تحلیل می‌کند، این بررسی در حالتی انجام شده که شرط استقلال دسته بندی کننده‌ی ساده‌ی بیز ممکن است درست نباشد (نکته در این است که شروطی وجود دارد که دسته بندی درست باشد اما احتمالات ثانویه درست نباشند).
- Cestnik (1990) بحث درباره‌ی استفاده از تخمین  $m$  برای دسته بندی احتمالات را مطرح می‌کند.
- نتایج تجربی که از مقایسه‌ی روش‌های مختلف بیزی و درخت تصمیم و دیگر الگوریتم‌های یادگیری انجام شده در Michie et al. (1994) آورده شده است. Chauvin and Rumelhart (1995) بررسی بیزی شبکه های عصبی را که بر اساس الگوریتم backpropagation است را مطرح می‌کنند.
- بحث بر روی قانون کمترین طول توضیح را می‌توانید در Rissanen (1983, 1989) بیابید. Quinlan and Rivest (1989) نیز استفاده از این قانون را در اجتناب از overfit در درخت‌های تصمیم را بررسی می‌کنند.

## تمرینات

۶.۱ دوباره مثال عملی قانون بیز در قسمت ۶.۲.۱ را در نظر بگیرید. فرض کنید که دکتر تصمیم می‌گیرد که دستور دهد که آزمایش دومی انجام شود، و فرض کنید که نتیجه‌ی آزمایش دوم نیز مثبت است. احتمال ثانویه‌ی  $\text{cancer}$  و  $\neg\text{cancer}$  را محاسبه کنید. فرض کنید که دو تست مستقلند.

۶.۲ در مثال قسمت ۶.۲.۱ احتمال ثانویه‌ی  $\text{cancer}$  را با نرمالیزه کردن  $P(+|\text{cancer}) \cdot P(\text{cancer})$  و  $P(+|\neg\text{cancer}) \cdot P(\neg\text{cancer})$  به صورتی که مجموعشان یک شود محاسبه کردیم. از قضیه‌ی بیز قضیه مجموع احتمالات (با توجه به جدول ۶.۱) برای اثبات این متد استفاده کنید. (ثابت کنید که نرمالیزه کرده به این صورت مقدار درستی برای  $P(\text{cancer}|+)$  ارائه می‌کند).

۶.۳ الگوریتم یادگیری مفهوم FindG را در نظر بگیرید، که کلی‌ترین فرضیه‌ی ممکن ساخته شده از فرضیه‌ها را ارائه می‌کند (کلی‌ترین اعضای فضای فرضیه ای متناسب با نمونه های آموزشی).

(a) توزیعی برای  $P(h)$  و  $P(D|h)$  ارائه کنید (فرض کنید FindG تضمین می‌کند که همیشه فرضیه ای MAP خروجی دهد)

(b) توزیعی برای  $P(h)$  و  $P(D|h)$  ارائه کنید (فرض کنید FindG تضمین نمی‌کند که همیشه فرضیه ای MAP خروجی دهد)

(c) توزیعی برای  $P(h)$  و  $P(D|h)$  ارائه کنید (فرض کنید FindG تضمین نمی‌کند که همیشه فرضیه ای ML خروجی دهد)

۶.۴ در بررسی یادگیری مفهوم در بخش ۶.۳ فرض کردیم که ترتیب نمونه های  $\langle x_1, \dots, x_m \rangle$  همیشه ثابت است. بنابراین برای استخراج عبارتی  $P(D|h)$  فقط کافی است که احتمال مشاهده‌ی سری‌ای از مقادیر هدف  $\langle d_1, \dots, d_m \rangle$  را برای این سری ثابت نمونه‌ها بررسی کنیم. حالت کلی‌تری را که در آن نمونه‌ها ثابت نیستند را در نظر بگیرید، اما فرض کنید که تمامی نمونه‌ها با توزیع مشخصی روی  $X$  انتخاب می‌شوند. داده های  $D$  را باید اکنون به فرم زوج‌های مرتب  $\{\langle x_i, d_i \rangle\}$  نشان داده و در  $P(D|h)$  باید احتمال حضور  $x_i$  ها را علاوه بر  $d_i$  دخیل کرد. نشان دهید که رابطه‌ی ۶.۵ در این حالت کلی‌تر نیز درست است. (راهنمایی: بررسی رابطه‌ی ۶.۵ را نیز در نظر بگیرید)

۶.۵ قانون کمترین طول توضیح را در نظر بگیرید که به فضای فرضیه ای  $H$  ی که شامل عطف  $n$  متغیر منطقی است اعمال می‌شود. واضح است که هر فرضیه به سادگی با ویژگی‌های موجود در فرضیه توصیف می‌شود، اگر تعداد بیت‌های لازم برای هر یک از متغیرها  $\log_2 n$  است. فرض کنید که کد سازی هر نمونه با داشتن فرضیه نیاز به صفر بیت دارد اگر نمونه سازگار با فرضیه باشد و نیاز به  $\log_2 m$  بیت دارد اگر نمونه با فرضیه سازگار نباشد،  $m$  تعداد نمونه‌هایی است که اشتباه دسته بندی می‌شوند. (برای تعیین اینکه کدام یک از  $m$  نمونه‌ی اشتباه دسته بندی شده، دسته بندی درست را می‌توان به نقیض آنچه فرضیه دسته بندی می‌کند دانست)

(a) رابطه‌ی لازم برای کمیتی که باید بنا بر قانون کمترین طول مینیمم شود را بیابید.

(b) آیا ممکن است که دسته ای از داده های آموزشی موجود باشد که فرضیه ای سازگار با آن‌ها وجود داشته باشد اما MDL فرضیه ای با سازگاری کمتر را برگزیند؟ اگر چنین است ان مجموعه را بیابید. اگر خیر، توضیح دهید چرا.

(c) توزیع احتمال  $P(h)$  و  $P(D|h)$  را برای اینکه الگوریتم MDL فوق فرضیه ای MAP را خروجی دهد بیابید.

۶۶ شبکه‌ی باور بیزی‌ای را که فرض استقلال دسته بندی کننده‌ی ساده‌ی بیز را برای مفهوم PlayTennis در مسئله‌ی قسمت ۶.۹.۱ بکشید. جدول احتمال شرطی مربوطه‌ی گره باد را نیز رسم کنید.

## فرهنگ لغات تخصصی فصل (فارسی به انگلیسی)

prior probability	احتمال اولیه
posterior probability	احتمال ثانویه
cross entropy	آنترپی دورگه
equivalent sample size	اندازه‌ی نمونه‌ی معادل
brute-force	بدون شعور
Outcome	برآمد
m estimate	تخمین m
problem setting	تعریف مسئله
probability mass	جرم احتمال
probability density	چگالی احتمال
bayes optimal classifier	دسته بندی کننده‌ی بهینه‌ی بیز
naive Bayes classifier	دسته بندی کننده‌ی ساده‌ی بیز
Descendant	زیرین
bayesian belief networks	شبکه‌های باور بیزی
Maximum A Posteriori	فرضیه با حداکثر احتمال
joint space	فضای توأم
Minimum description length	قانون کمترین طول توضیح
Gibbs algorithm	الگوریتم گیبس
maximum likelihood	محتمل‌ترین
Criterion	معیار
consistent learner	یادگیر سازگار
Arc	یال